受众定向
(Audience targeting)

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

中国互联网用户桌面

师徒 Sheetoo

受众售卖 vs 广告位售卖

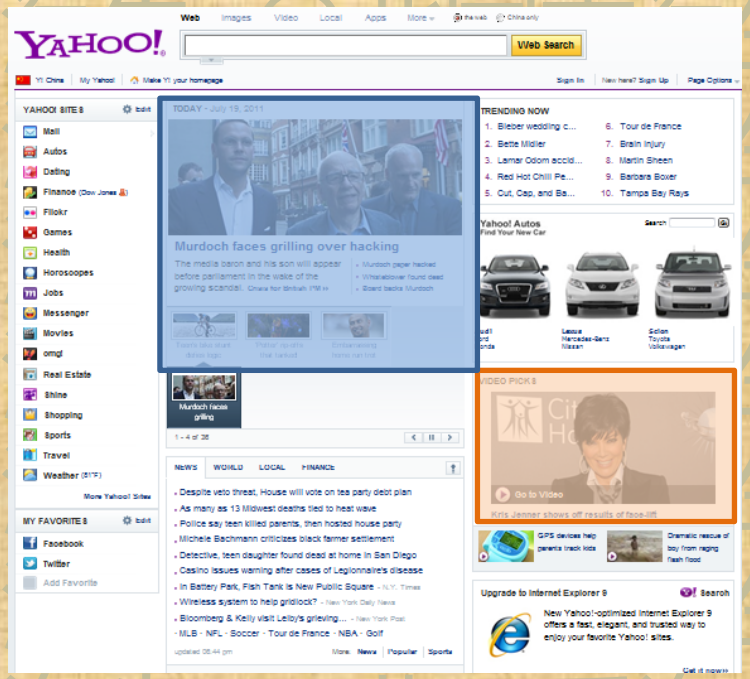

@北冥乘海生

A(d)U(ser)C(txt)上的标签体系

- 受众定向即为AUC打标签的过程
  - 上下文标签可以认为是即时受众标签
- 标签的两大主要作用
  - 建立面向广告主的流量售卖体系
  - 为各估计模块(如CTR预测)提供原始特征

@北冥乘海生 师徒 Sheetoo

师徒 Sheetoo

常见受众定向方式

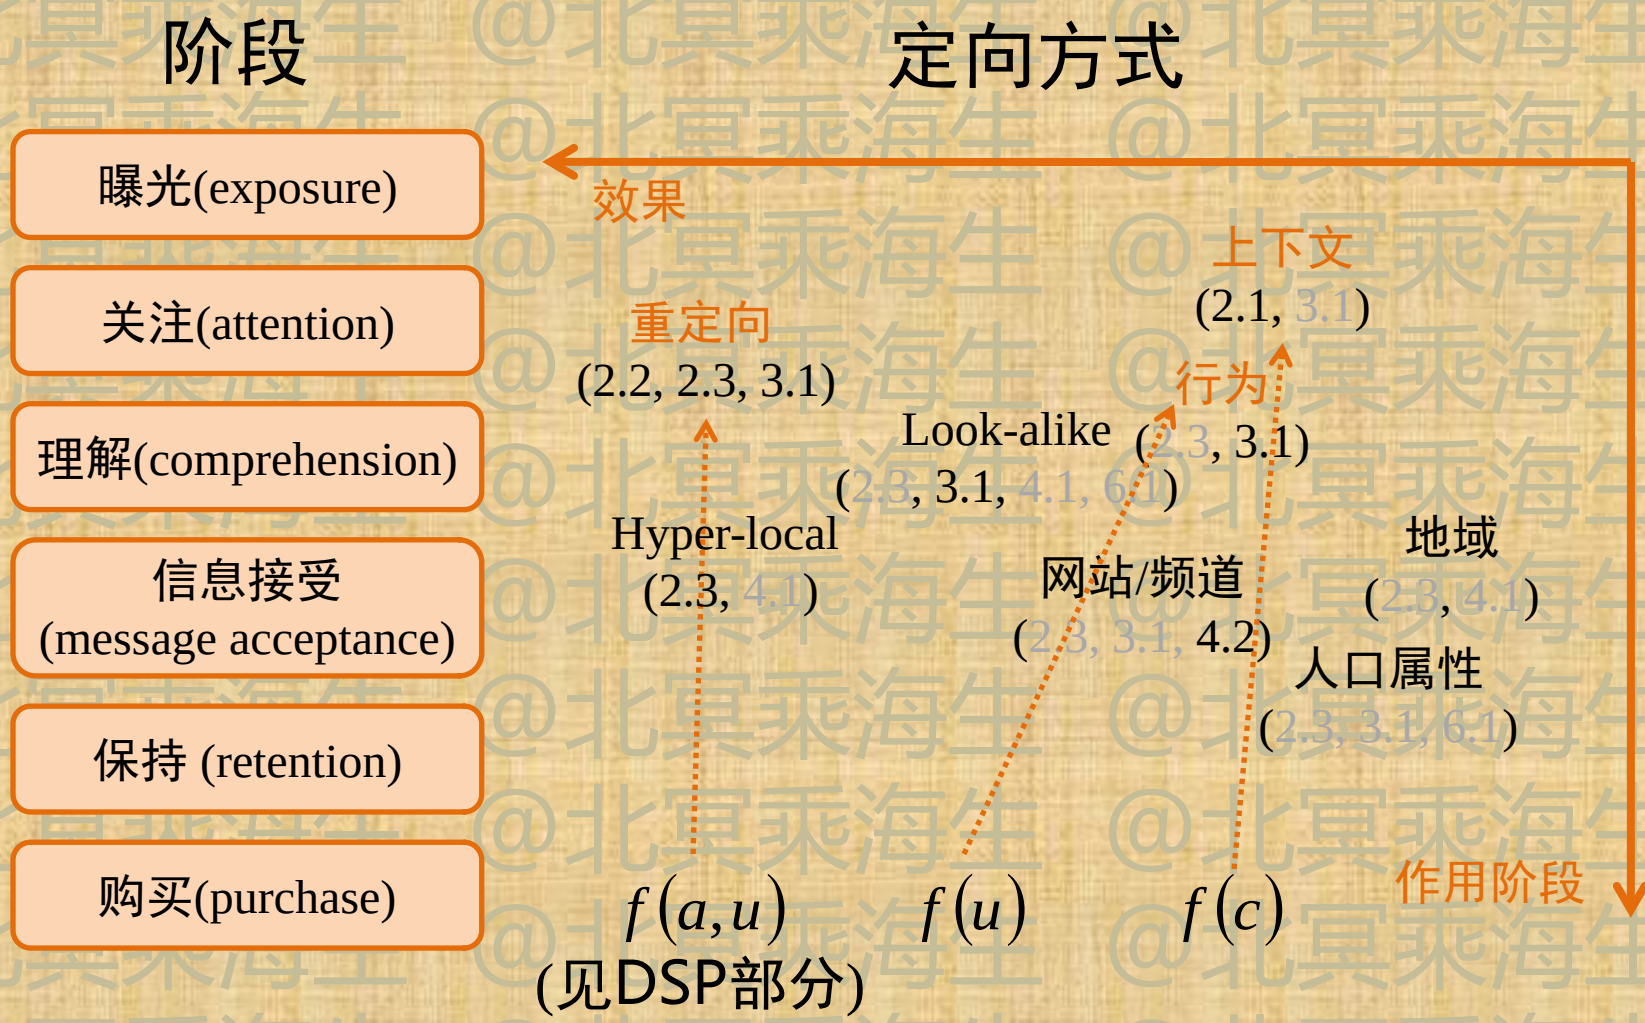

师徒 Sheetoo

Audience Science™

- 核心业务：
  - 主要提供面向publisher的数据加工服务
  - 直接运营ad network，并帮助广告主进行campaign管理和优化
- 其他点评：
  - 较早提出受众定向(audience targeting)的概念
  - 数据标签不像bluekai那样在市场上公开出售, 仅供委托他们优化campaign的广告商使用
  - 使用标签impression创造的营收按照一定比例跟publisher分成

@北冥乘海生

师徒 Sheetoo

行为定向(Behavioral Targeting)

- 九种重要原始行为(按信息强度排序)
  - Transaction, Pre-transaction(如商品浏览), Paid search click, Ad click, Search click, Search, Share, Page View, Ad view
- 行为定向计算 ($t^{(i)}(u)$表示用户u在标签i上的强度)

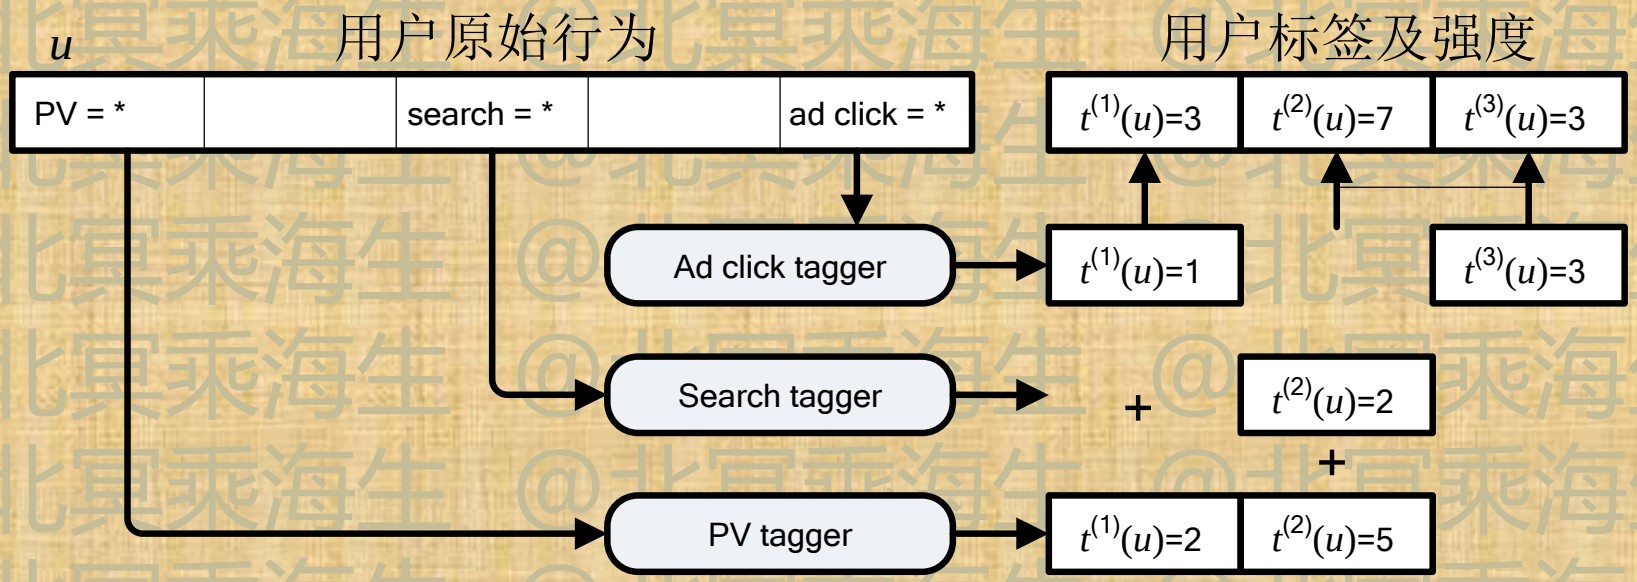

师徒 Sheetoo

行为定向其他问题

- Session log
  - 将各种行为日志整理成以用户ID为key的形式，完成作弊和无效行为标注，作为各数据处理模块的输入源
  - 可以将targeting变成局部计算，大大方便整个流程
- Long-term行为定向两种多日累积方式
  - 滑动窗方式(f 为long-term标签, 下标为日期)

$$f_d^{(i)}(u) = \sum_{j=0}^{T} t_{d-j}^{(i)}(u)$$

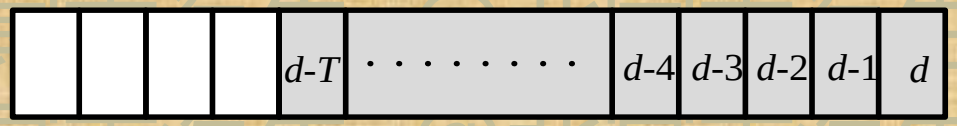

  - 时间衰减方式(空间复杂度低，仅需昨天的f 和今天的t)

$$f_d^{(i)}(u) = t_d^{(i)}(u) + \alpha f_{d-1}^{(i)}(u)$$

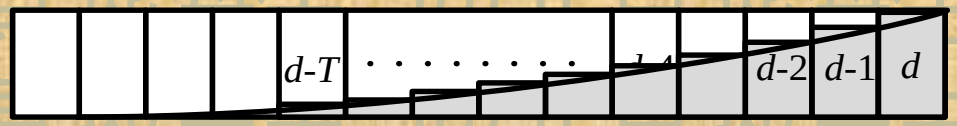

受众定向评测 – Reach/CTR曲线

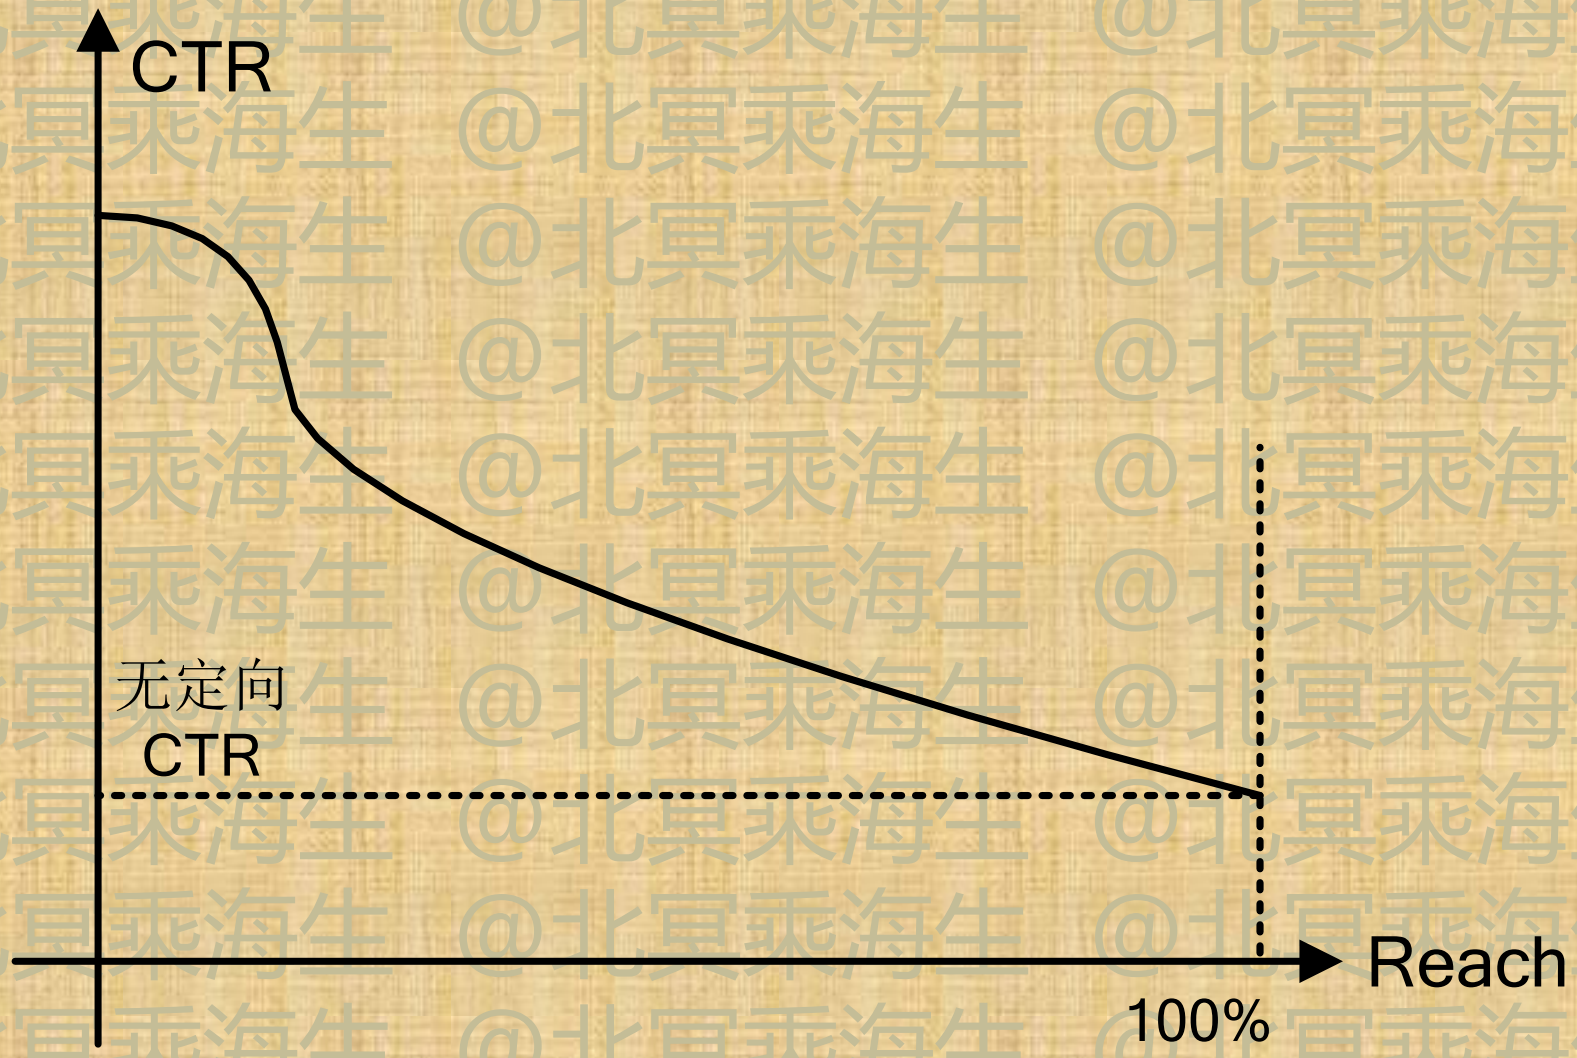

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

上下文定向(Contextual targeting)

- Near-line上下文定向系统
  - 用在线cache系统存储url -> 特征表以提供实时访问
  - 不预先加载任何cache内容，对cache中不存在的url, 立刻返回空特征, 同时触发相应的页面爬虫和特征提取
  - 设置cache系统合适的失效时间以完成特征自动更新

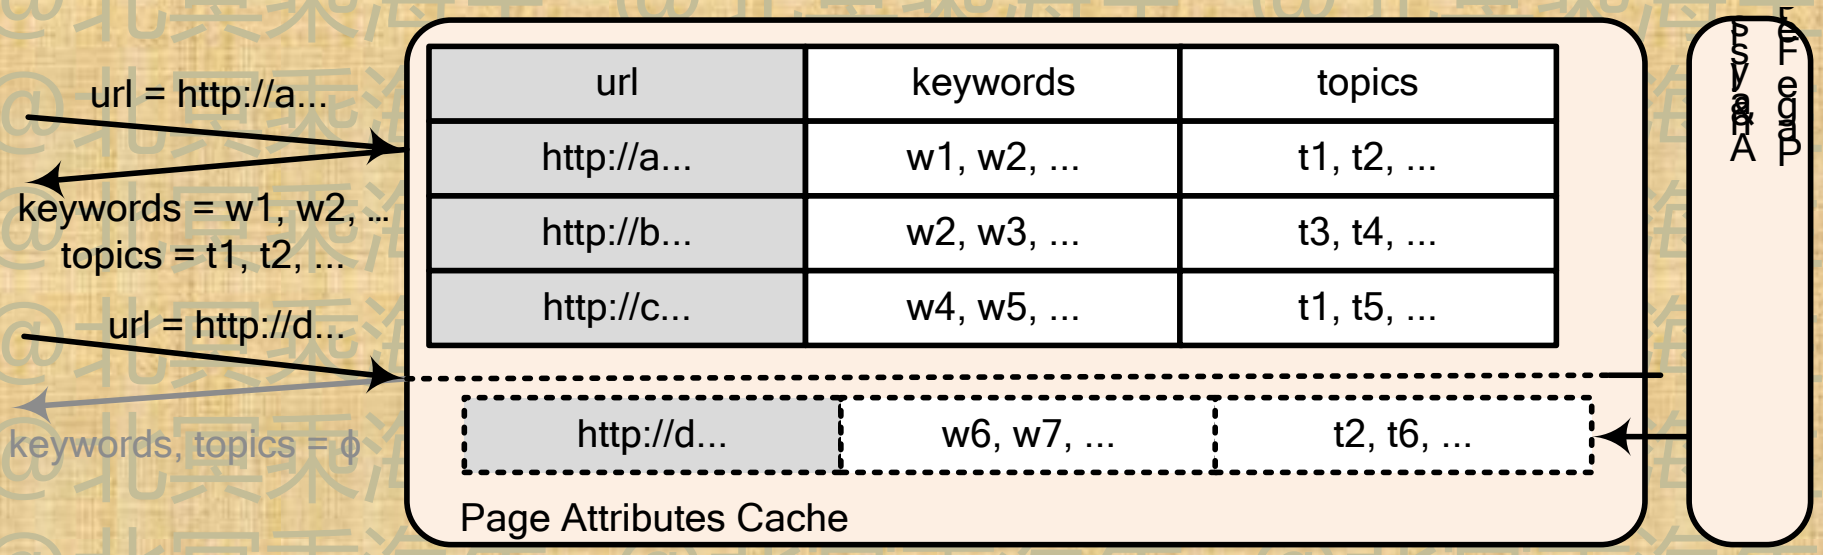

url	keywords	topics
http://a...	w1, w2, ...	t1, t2, ...
http://b...	w2, w3, ...	t3, t4, ...
http://c...	w4, w5, ...	t1, t5, ...
http://d...	w6, w7, ...	t2, t6, ...

页面主题分析 - Topic Model

- 问题: 发现一组文档中抽象的主题(topics)
- 常用模型图表示
  - PLSI

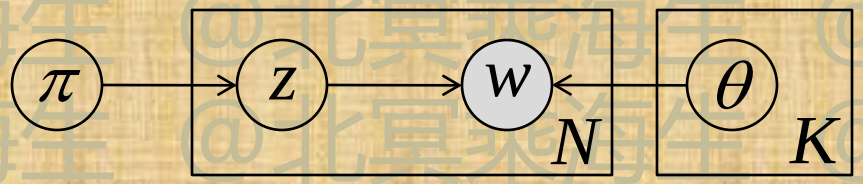

$p(w|\bullet), p(z|\bullet)$: Multinomial

$p(\pi|\bullet), p(\theta|\bullet)$: Dirichlet

  - LDA(Latent Dirichlet allocation)

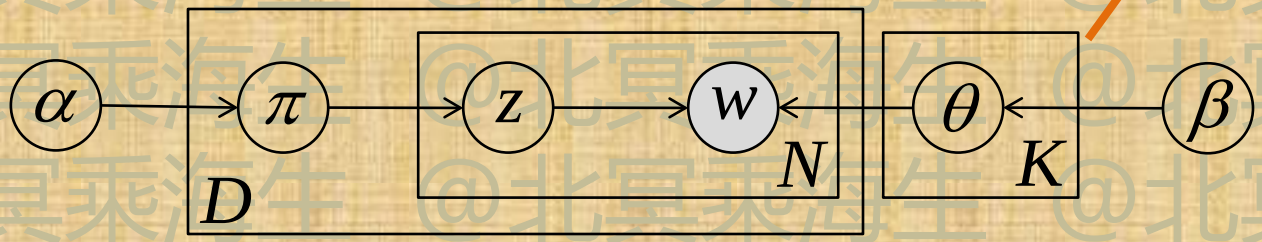

  - GaP (Gamma-Poisson)

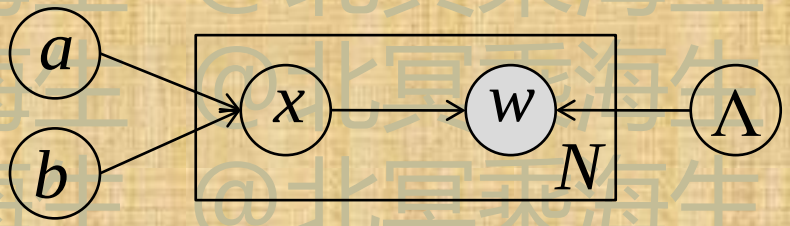

$p(z|\bullet)$: Gamma

$p(w|\bullet)$: Poisson

@北冥乘海生 师徒 Sheetoo

经验贝叶斯 – Empirical Bayes

- 如下图模型, 如何确定hyperparameter η ?

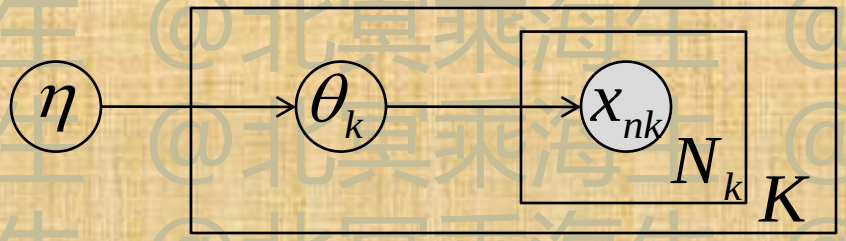

- EB解: $\hat{\eta} = \arg\max_{\eta} \int \prod_{k=1}^{K} p(D_k \mid \theta_k) p(\theta_k \mid \eta) \mathrm{d}\theta_k$
- 当 $p(x \mid \theta)$ 为指数族分布，$p(\theta \mid \eta)$ 为其共轭先验时，可用EM求解, 其中E-step为Bayesian inference过程, 由 η^{old} 得到后验参数 $\tilde{\eta}_k^{\text{old}}$, 而M-step为:

$$\langle \theta, \ln[g(\theta)] \rangle_{\eta^{\text{new}}} = \frac{1}{K} \sum_{k=1}^{K} \langle \theta, \ln[g(\theta)] \rangle_{\tilde{\eta}_k^{\text{old}}}$$

师徒 Sheetoo

从经验贝叶斯看LDA

- LDA可以视为PLSI的经验贝叶斯版本
  - 由于PLSI不是指数族分布，而是其混合分布，因此其贝叶斯版本不能使用前面的EM算法
- Deterministic inference:
  - 可用变分近似，假设z和θ的后验分布独立迭代求解过程与EM非常相似，称为VBEM
  - 在大多数问题上无法保证收敛到局部最优
- Probabilistic inference:
  - 可用Gibbs-sampling(Markov-chain Monte-Carlo, MCMC, 的一种)，以概率1收敛到局部最优值
  - Collapsed Gibbs-sampling: $$p(z_i = j | z_{-i}) = \frac{n_{-i,j}^{(w_i)} + \beta}{n_{-i,j}^{(\cdot)} + W\beta} \frac{n_{-i,j}^{(d_i)} + \alpha}{n_{-i,j}^{(d_i)} + T\alpha}$$

@北冥乘海生

师徒 Sheetoo

Topic model的并行化

- EM及VBEM的并行化
  - E-step(mapper): 可以方便地并行计算
  - M-step(reducer): 累加E-step各部分统计量后更新模型
  - 将更新后的模型分发到新的E-step各个计算服务器上
- AD-LDA: Gibbs Sampling的并行化
  - Mapper: 在部分data上分别进行Gibbs sampling
  - Reducer: 全局Update

$$n_{i,j} \leftarrow n_{i,j} + \sum_p \left(n_{i,j,p} - n_{i,j}\right), \qquad n_{i,j,p} \leftarrow n_{i.j}$$

- 文档的Topic model抽取可以认为是一个大量(而非海量)数据运算，采用类MPI架构的分布式计算架构(例如spark)会比map/reduce效率更高

@北冥乘海生

数据加工和交易

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

精准广告业务是什么？

油田

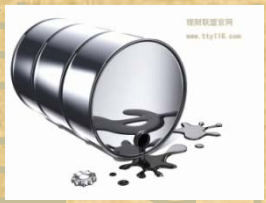

原油

炼油厂

汽油

加油站

数据源

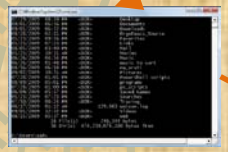

原材料

用户行为

定向系统

用户标签

理财　体育　电子

投放机

@北冥乘海生

师徒 Sheetoo

精准广告业务若干错误观念

- 越精准的广告，给市场带来的价值越大
- 媒体利益与广告主利益是相博弈的关系
- 精准投放加上大数据可以显著提高营收
- 人群覆盖率较低的数据来源是不需要的
- 不同的广告产品应该采用不同的投放机

@北冥乘海生

师徒 Sheetoo

有价值的数据

- 用户标识
  - 除上下文和地域外各种定向的基础，需要长期积累和不断建设
  - 可以通过多家第三方ID绑定不断优化
- 用户行为
  - 业界公认有效行为数据（按有效性排序）
    - 交易，预交易，搜索广告点击，广告点击，搜索，搜索点击，网页浏览，分享，广告浏览
  - 需去除网络热点话题带来的偏差
  - 越靠近demand的行为对转化越有贡献
  - 越主动的行为越有效

@北冥乘海生

师徒 Sheetoo

有价值的数据

- 广告商(Demand)数据
  - 简单的cookie植入可以用于retargeting。
  - 对接广告商种子人群可以做look-alike，提高覆盖率。
- 用户属性和精确地理位置
  - 非媒体广告网络很难获取，需通过第三方数据对接。
  - 移动互联和HTML5为获得地理位置提供了便利性。
- 社交网络
  - 朋友关系为用户兴趣和属性的平滑提供了机会
  - 实名社交网络的人口属性信息相对准确

@北冥乘海生

数据管理平台
(Data Management Platform)

- 目的:
  - 为网站提供数据加工和对外交易能力
  - 加工跨媒体用户标签，在交易市场中售卖
  - 是否应直接从事广告交易存在争议
- 关键特征:
  - 定制化用户划分
  - 统一的对外数据接口
- 代表:
  - Bluekai, AudienceScience

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

DMP系统架构示意

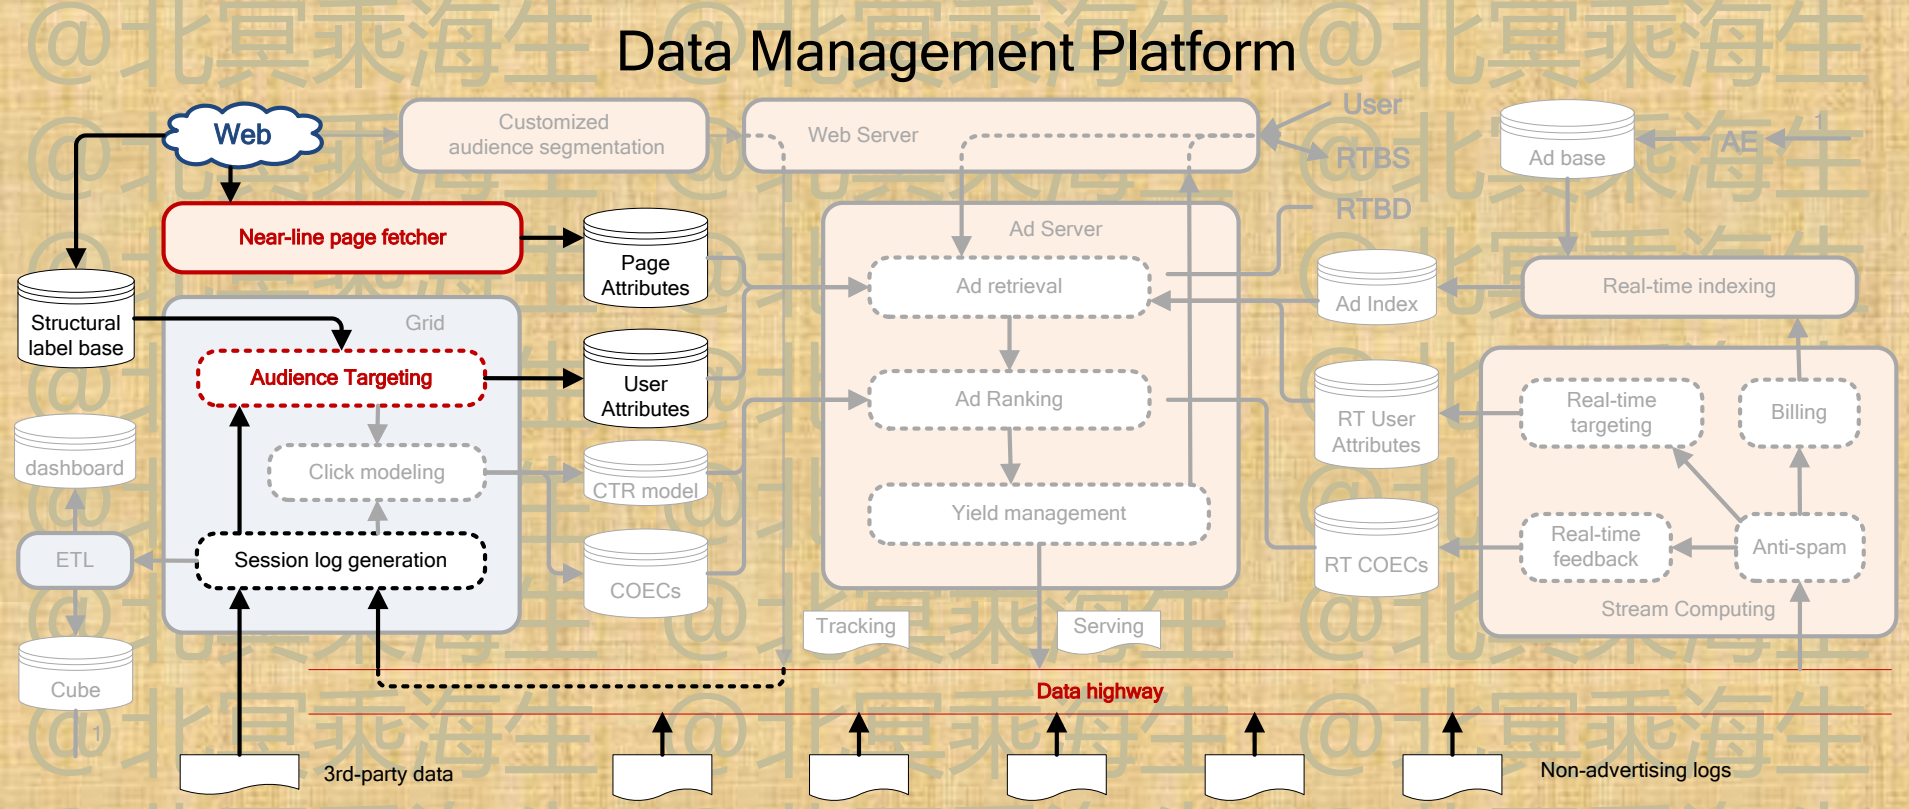

师徒 Sheetoo

Data Highway工具

- Scribe:
  - 大规模分布式日志收集系统，可以准实时收集大量日志到HDFS，利用Thrift实现底层服务
  - 类似工具: Flume, Chukwa

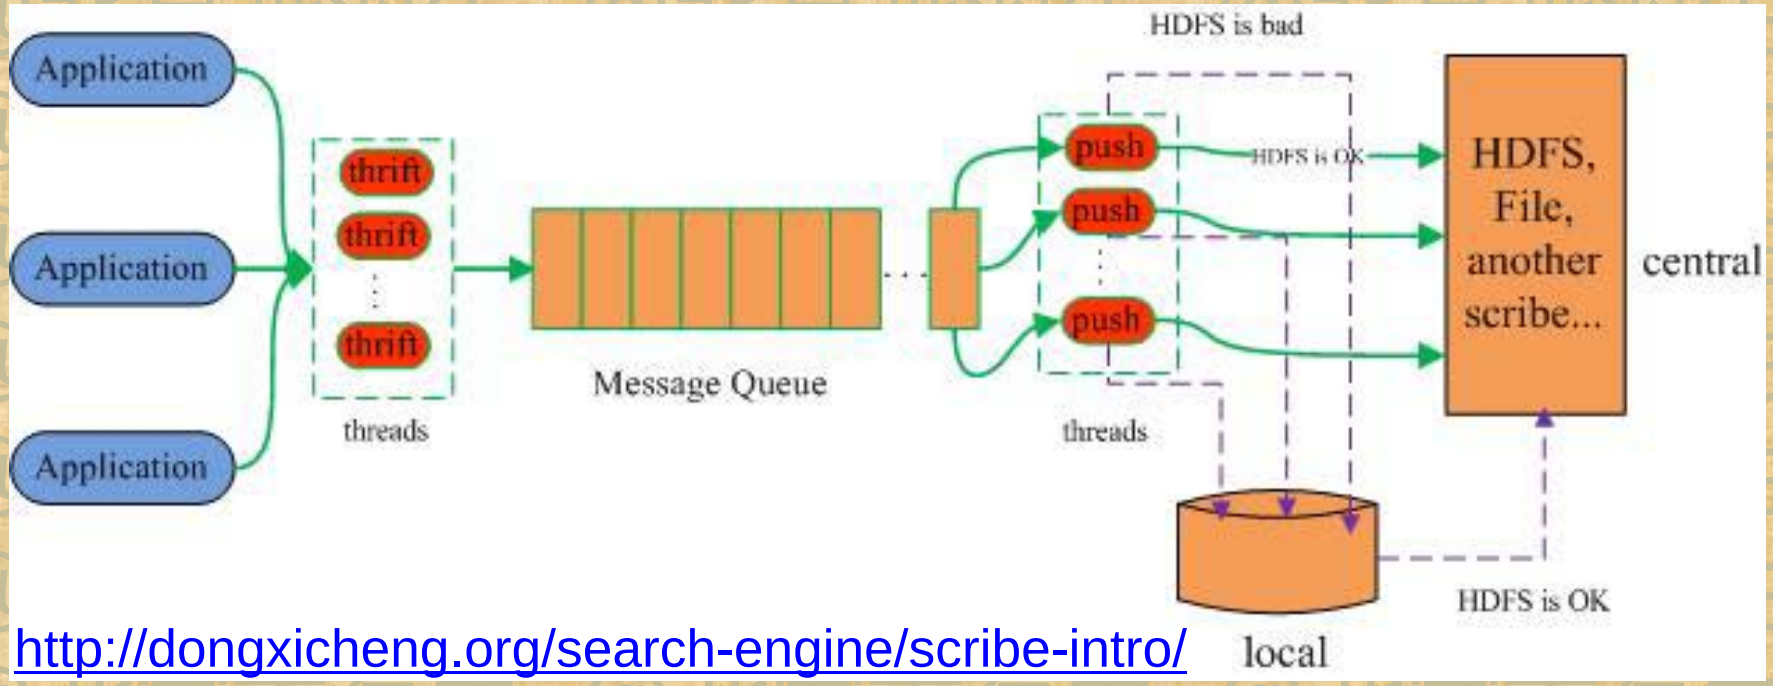

http://dongxicheng.org/search-engine/scribe-intro/

师徒 Sheetoo

- 核心业务：
  - 为中小网站主提供数据加工和变现的方式
  - 通过汇聚众多中小网站用户资料和行为数据，加工成受众定向标签，通过Data exchange对外售卖
- 其他点评：
  - 提供大量细分类别、开放体系上的标签，如“对宝洁洗发水感兴趣的人”，“想去日本旅游的人”
  - 靠数据出售变现，并与提供数据的网站主分成，并不直接运营广告业务
  - 用户可以看到自己的资料被谁使用，也可以选择“捐给慈善机构”

@北冥乘海生

竞价广告系统

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

竞价系统理论

- 位置拍卖(Position auctions)
  - 将对象 $a=\{1, 2, \ldots A\}$ 排放到位置$s=\{1, 2, \ldots, S\}$
  - 对象a的出价(bid)为b_a，而其对位置s的计价为 $u_{as}=v_a x_s$,$(x_1>x_2>\ldots>x_S)$
  - 将v_a视为点击价值，x_s视为点击率，该模型可近似描述广告系统竞价问题(对显示广告，$S = 1$)
- 对称纳什均衡(Symmetric Nash equilibrium)
  - $(v_s - p_s)\, x_s >= (v_s - p_t)\, x_t$，其中$p_t = b_{s+1}$
  - 寻找收入最大化且稳定的纳什均衡状态是竞价系统设计的关键

@北冥乘海生

师徒 Sheetoo

定价机制

- VCG(Vickrey–Clarke–Groves)机制
  - 某对象的收费应等于给他人带来的价值损害

$$p_s = \sum_{t>s} v_t (x_{t-1} - x_t)$$

  - 整体市场是truth-telling的
- 广义第二高价(Generalized second pricing)机制

$$p_s = b_{s+1} + 1$$

  - 与VCG机制相比，会收取广告主更多的费用
  - 整体市场不是truth-telling的
  - 简单易行，为在线广告系统广泛采用

@北冥乘海生

广告网络(Ad Network)

- 广告网络:
  - Connects advertisers to web sites that want to host advertisements (见Wikipedia)
  - 自行估计给定(a, u, c)组合的CTR
- 主要特征:
  - 竞价系统(Auction system)
  - 淡化广告位概念
  - 最合适的计价方式为CPC
  - 不足：不易支持定制化用户划分

@北冥乘海生 @北冥乘海生 @北冥乘海生
师徒 Sheetoo