动态特征 - 多层次点击反馈

- 在标签组合维度上聚合点击反馈统计作为CTR预测的特征
- 优势:
  - 工程架构扩展性强(与在线学习相比)
  - 对新(a, u, c)组合有较强back-off能力
- 缺点:
  - 在线特征的存储量大，更新要求高
- 组合维度举例:
  - cookie(u) and creative(a)
  - gender(u) and topic(c)
  - location(u) and advertiser(a)
  - Category(a) and category(u)
  - cookie(u)
  - creative(a)
  - gender(u)

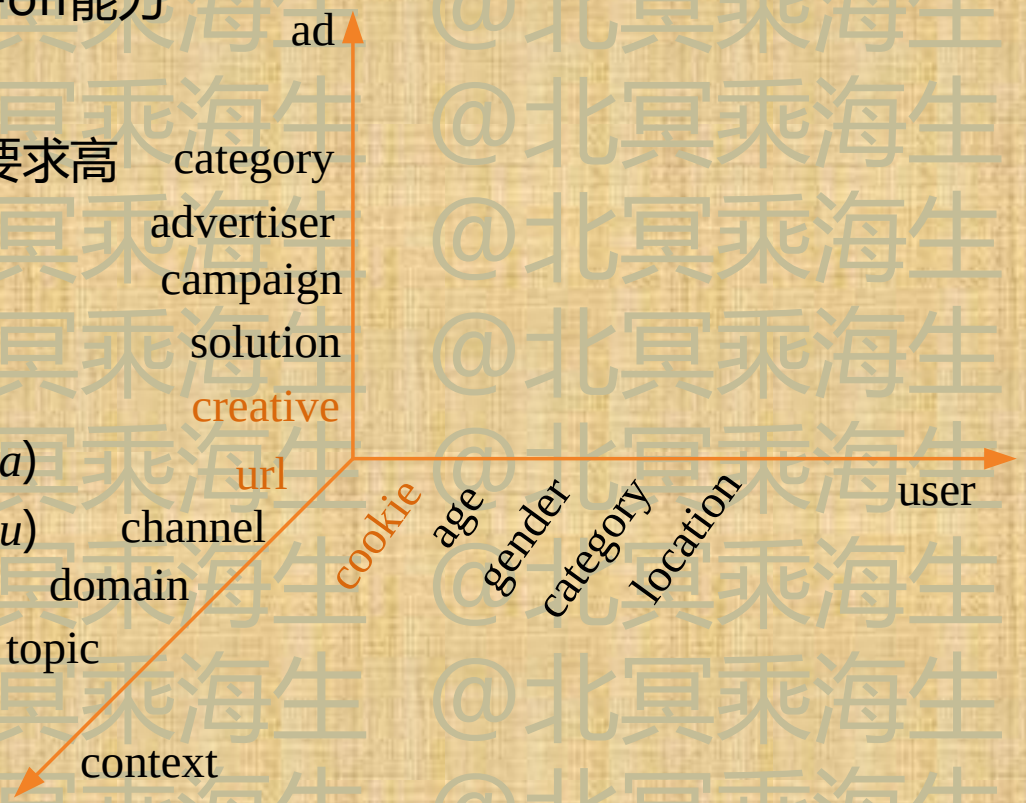

@北冥乘海生
师徒 Sheetoo

师徒 Sheetoo

归一化点击率特征 - COEC

- 有效展示
  - 可以通过Eye tracking测算
  - 工程上可以使用Expected Click (EC)来近似有效展示
- EC的计算
  - 实测法：实际随机流量测算
  - Bias模型法：只使用与广告决策无关的bias特征训练的CTR模型：$\mathrm{EC} = p_{\mathrm{bias}}(a,u,c)$
- 归一化点击率

$$\mathrm{COEC} = \sum_i \mathrm{click}_i \Big/ \sum_i \mathrm{EC}_i$$
$$= \sum_i \mathrm{click}_i \Big/ \sum_i p_{\mathrm{bias}}(a_i,u_i,c_i)$$

是同样有效的展示么？

@北冥乘海生

师徒 Sheetoo

在线广告常见bias特征

- 广告位位置
  - 搜索广告：North 1, North 2, …, East 1, East 2, …
  - 显示广告：相对页面的(x, y)
- 广告位尺寸
- 广告位类型
  - 门户首页, 频道首页, 内容页, 客户端, …
- 创意类型
  - 图片, flash, 富媒体, …
- 操作系统和浏览器
- 日期和时间

@北冥乘海生

点击反馈的平滑

- 问题: 在数据稀疏的情况下较稳健地估计CTR或COEC
- 经验贝叶斯方案
  - 点击产生概率模型(Binomial分布, 其中μ为点击率):

$$p(x \mid \mu) = \mu^{x}(1-\mu)^{1-x}$$

  - 视μ为随机变量, 采用Beta分布共轭先验进行regularization:

$$p(\mu \mid \theta = \{a,b\}) = \mathrm{Beta}(\mu; a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}\mu^{a-1}(1-\mu)^{b-1}$$

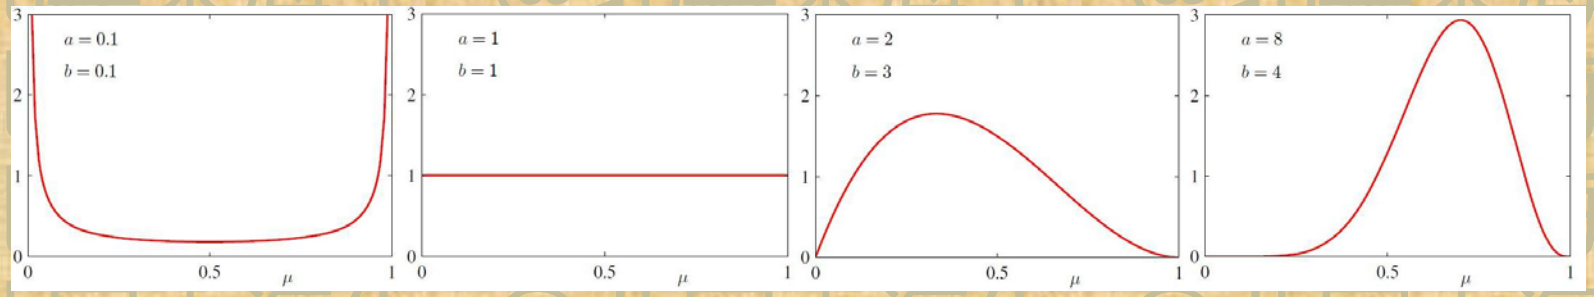

  - 生成模型图示意:

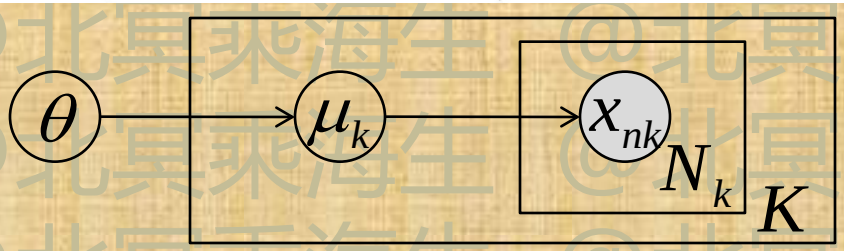

经验贝叶斯解

- E-step: $\tilde{a}_k^{\text{old}} = a^{\text{old}} + \sum_{n=1}^{N_k} x_{k,n}, \tilde{b}_k^{\text{old}} = b^{\text{old}} + \left(N_k - \sum_{n=1}^{N_k} x_{k,n}\right)$
- M-step: $\psi\left(a^{\text{new}}\right) - \psi\left(a^{\text{new}} + b^{\text{new}}\right) = \frac{1}{K}\sum_{k=1}^{K} \psi\left(\tilde{a}_k^{\text{old}}\right) - \psi\left(\tilde{a}_k^{\text{old}} + \tilde{b}_k^{\text{old}}\right)$

$$\psi\left(b^{\text{new}}\right) - \psi\left(a^{\text{new}} + b^{\text{new}}\right) = \frac{1}{K}\sum_{k=1}^{K} \psi\left(\tilde{b}^{\text{old}}\right) - \psi\left(\tilde{a}^{\text{old}} + \tilde{b}^{\text{old}}\right)$$

- 点击率的平滑通常在每个维度组合上分别进行
- 物理意义：
  - 数据不足时，更依赖于相应维度组合的点击率先验值
  - 维度组合内的点击率分散程度对先验值的作用有影响
- 思考：对COEC的平滑可以采用什么模型？

@北冥乘海生 师徒 Sheetoo

评测指标 – PR曲线

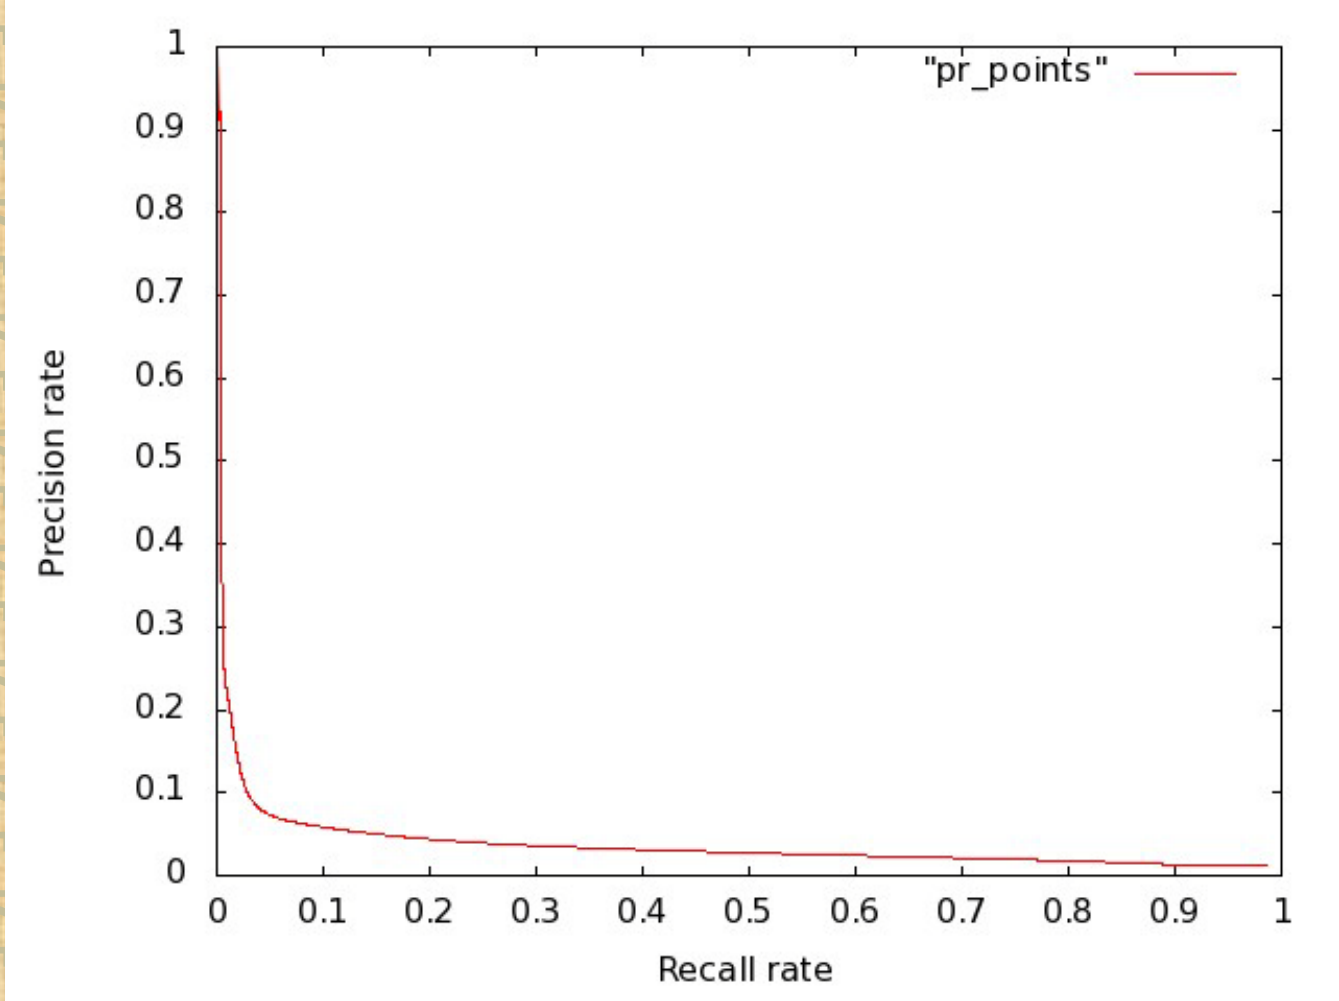

PR curve

@北冥乘海生

评测指标 – AUC

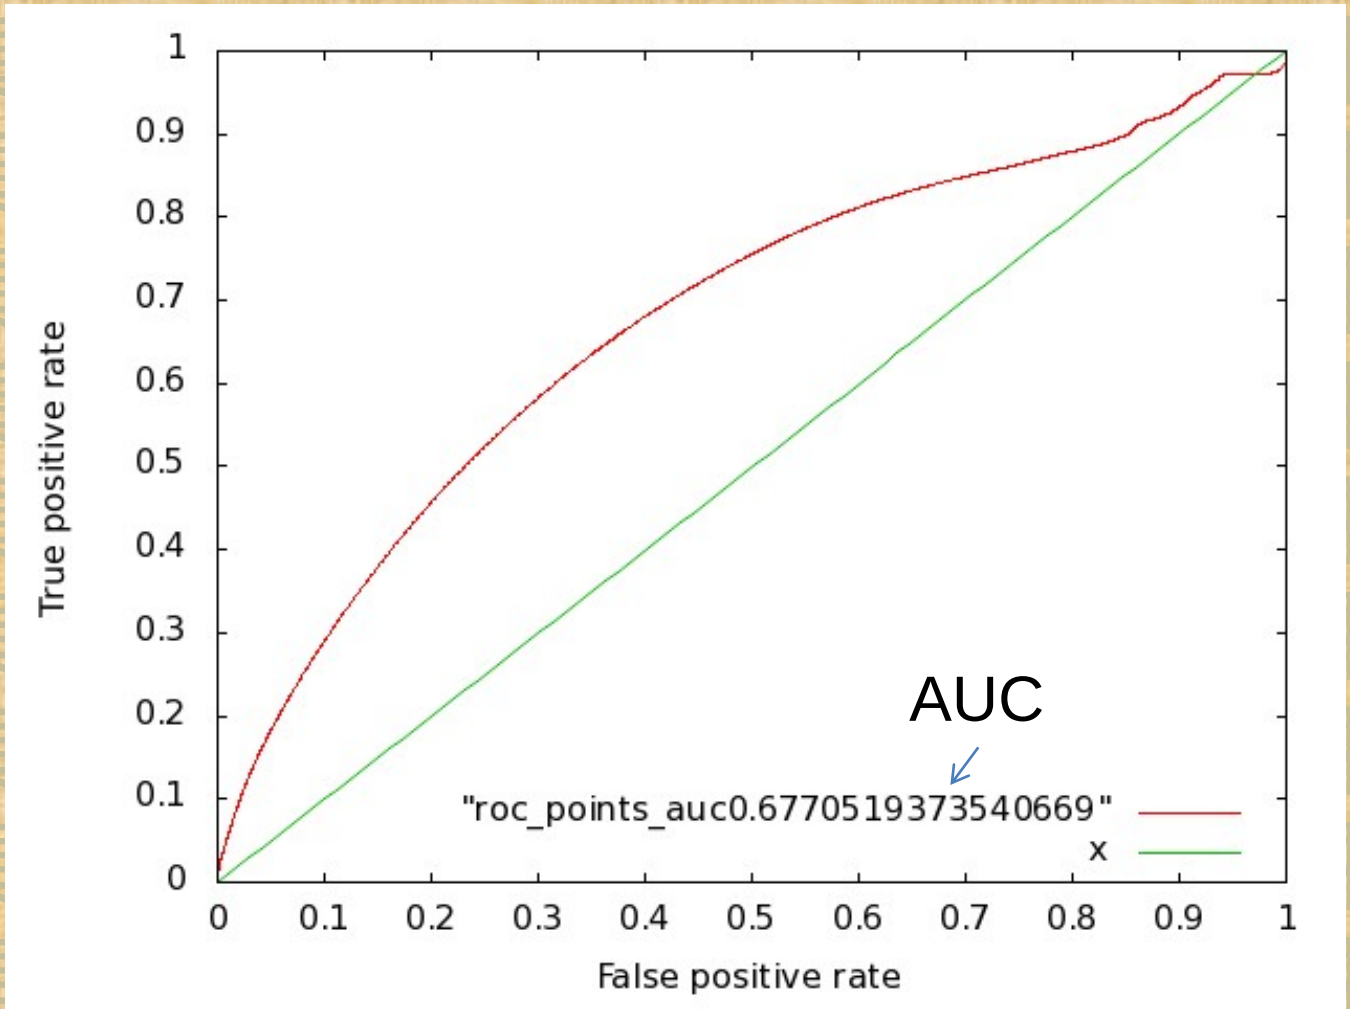

ROC curve

@北冥乘海生

探索与利用
(Explore and exploit)

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

探索与利用 (E&E)

- 问题
  - 为长尾的(a, u, c)组合创造合适的展示机会以积累统计量，从而更准确地估计其CTR
  - 提升整体的广告收入，即需要严格控制探索的量和有效性
- 方法思路
  - 通常描述为Multi-arm Bandit (MAB) 问题
    - 有限个arms(或称收益提供者)a, 每个有确定有限的期望收益$\mathrm{E}(r_{t,a})$
    - 在每个时刻t, 我们必须从arms中选择一个, 最终目标是优化整体收益
  - 基本方法为ε–greedy: 将ε比例的小部分流量用于随机探索
- 广告问题中的主要挑战
  - 海量的组合空间需要被探索
  - 各个arm的期望收益是动态变化的

@北冥乘海生

E&E 算法 - UCB

- 方法思路
  - 在时间t, 通过以往的观测值以及某种概率模型, 计算每个arm的期望收益的upper confidence bound (UCB)，并选择UCB最大的arm
  - 我们不可能一直选择非最优的arm, 原因是我们选择的此arm次数越多, 其UCB就越接近于其期望收益
- 具体UCB策略
  - β-UCB策略: 依一个很大的概率, 我们选择非最优arms的次数存在着一个上界, 该上界与总的选择次数无关
  - UCB-tuned策略: 我们已选择的次数越多, 就越可以自信地抛弃不太有前途(但仍有可能最优)的arm.

@北冥乘海生 @北冥乘海生 @北冥乘海生
师徒 Sheetoo

E&E 算法 – Contextual Bandit

- 问题描述
  - 对每次展示，每个arm(广告)a有一个对应的特征矢量$\boldsymbol{x}(u,a)$
  - 用此特征矢量代替arm本身进行Bandit决策
- LinUCB
  - Disjoint linear model: $\mathrm{E}\left(r_{t,a} \middle| \boldsymbol{x}_{t,a}\right) = \boldsymbol{x}_{t,a}^{\mathrm{T}} \theta_a$
  - 参数(θ)的岭回归(Ridge regression)解:

$$\hat{\boldsymbol{\theta}}_a = \left(D_a^{\mathrm{T}} D_a + I_d\right)^{-1} D_a^{\mathrm{T}} c_a$$

    - $\{D_a\}_{\#\text{特征维度} \times \#\text{样本数}}$为观测样本，$c_a$为回报(广告中是点击)矢量
  - 特征空间内的UCB策略:

$$a_t = \arg\max_a \left(\boldsymbol{x}_{t,a}^{\mathrm{T}} \hat{\boldsymbol{\theta}}_a + \alpha \sqrt{\boldsymbol{x}_{t,a}^{\mathrm{T}} \left(D_a^{\mathrm{T}} D_a + I_d\right)^{-1} \boldsymbol{x}_{t,a}^{\mathrm{T}}} \right)$$

@北冥乘海生 @北冥乘海生 @北冥乘海生
师徒 Sheetoo

师徒 Sheetoo

搜索广告
(Sponsored Search)

@北冥乘海生

师徒 Sheetoo

搜索广告特点

- 广告网络的特殊形式
  - 用户定向标签$f(u)$: 远远弱于上下文影响，一般可以忽略
  - Session内的短时用户搜索行为作用很重要
  - 上下文定向标签$f(c)$: 关键词
- 典型位置竞价模式
  - 分为北，南，东三个广告区块
  - 根据各位置的reference ctr决定各位置在竞价系统中的位次
  - reference ctr可以通过ε流量较准确测定出

@北冥乘海生

查询词扩展(Query Expansion)

- 基于推荐的方法
  - 挖掘(session, query)矩阵找到相关query, 可类比(user, item)矩阵
  - 利用的是搜索数据
- 基于语义的方法
  - 用topic model或概念化的方法中找语义相关query
  - 利用的是其他文档数据
- 基于收益的方法
  - 根据实际eCPM统计得到变现能力最好的相关query
  - 利用的是广告数据

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

用户相关的搜索广告决策

- 结果个性化对于搜索广告作用有限
  - 上下文信息(c)太强, 个人兴趣可以忽略
  - 搜索页上的结果需要保证主题上某种一致性
- 广告展示条数是可以深度个性化的
  - 约一半的用户无法明确区分广告与搜索结果
  - 在平均广告条数的约束下，可以对每个用户的广告条数进行个性化，以最大化营收
  - 又一个约束优化问题！
- 可以根据同一session内的行为调整广告结果

@北冥乘海生

师徒 Sheetoo

短时用户行为反馈

- 短时用户行为
  - 狭义: 用户在一个session内的行为
  - 广义: 用户在短时间(一般为一刀两天)内的行为
- 短时用户行为反馈
  - 短时受众定向: 根据短时行为为用户打上的标签
  - 短时点击反馈: 根据短时广告交互计算的动态特征
- 短时用户行为计算
  - 需要准实时(分钟级)对用户行为进行加工，不适合在Hadoop上进行
  - 可以利用流式计算(stream computing)平台, 如S4, Storm等

@北冥乘海生

流式计算平台 - Storm

- 大规模实时数据处理框架, 自动完成数据分发和可靠性管理, 开发者只需要关注处理逻辑.
- 数据流基本在网络和内存进行
- 计算逻辑类似Map/Reduce, 区别在调度数据而非调度计算

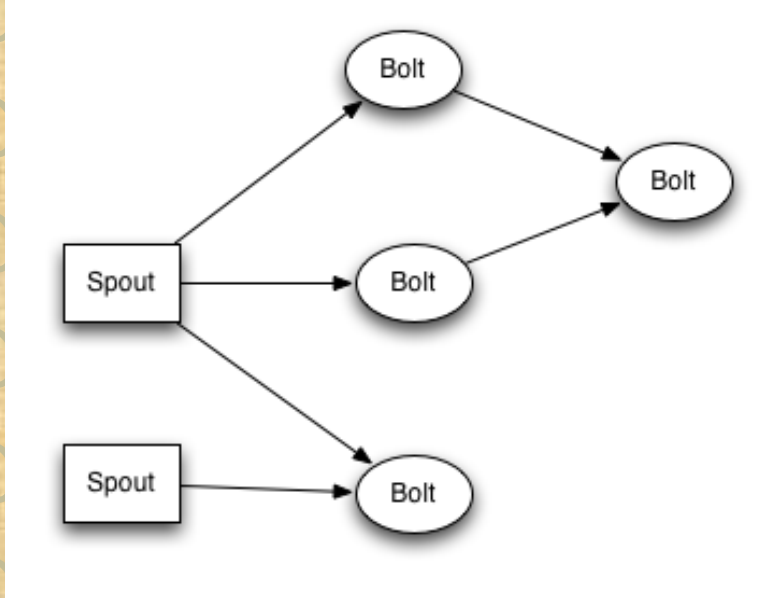

Topology

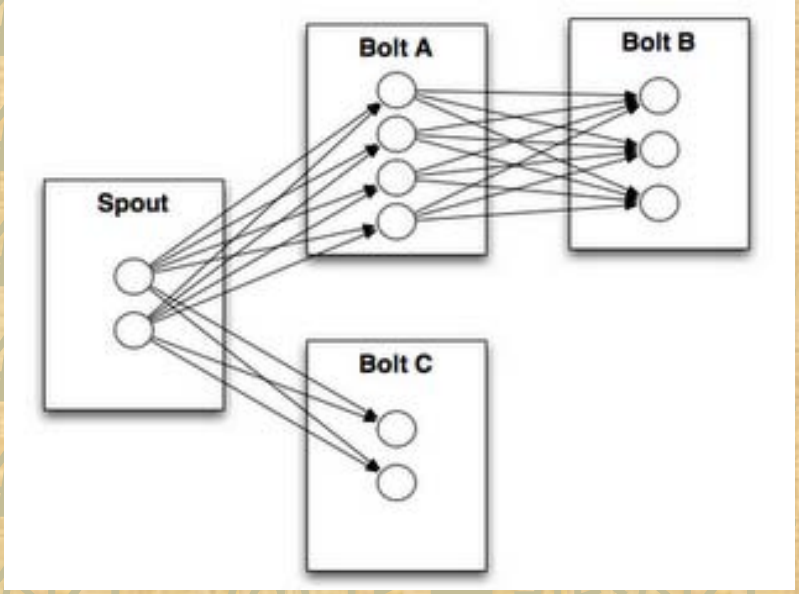

Tasks

@北冥乘海生 师徒 Sheetoo

广告网络Demand端技术

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

广告购买平台 (Trading Desk)

- 产品目标:
  - Allows advertisers buy audience across publishers and ad networks
- 关键特征:
  - 连接到不同媒体和广告网络，为广告商提供universal marketplace
  - 非实时竞价campaign的ROI优化能力
  - 经常由代理公司孵化出来

@北冥乘海生

师徒 Sheetoo

非RTB流量的ROI优化

- 目标:
  - 给定总预算，在多广告网络中采买并优化ROI(例: SEM)
- 若干关键问题:
  - 在合适的流量segment上投放广告
    - SEM中的选词
    - 显示广告网络中的标签组合选择
  - 在每个投放上合理地出价以优化ROI
    - 与RTB不同，采买方无法控制每次展示的出价
    - u, c的取值未知，需要在各流量分割上估计其分布并合理出价
  - 对每个segment的量以及Market price进行预估，以完成整体的优化

@北冥乘海生

师徒 Sheetoo

EfficientFrontier

- 核心业务：
  - 为搜索广告主提供大量关键词情形下的ROI优化服务，并收取固定比例的提成
  - 核心技术为Portfolio Optimization
  - 目前正在向显示广告领域扩张
- 其他点评：
  - 核心竞争力除了算法还来自于长时间数据积累
  - 被Adobe收购的原因是Omniture的数据，现改名Adobe Adlens

@北冥乘海生

在线广告市场结构示意

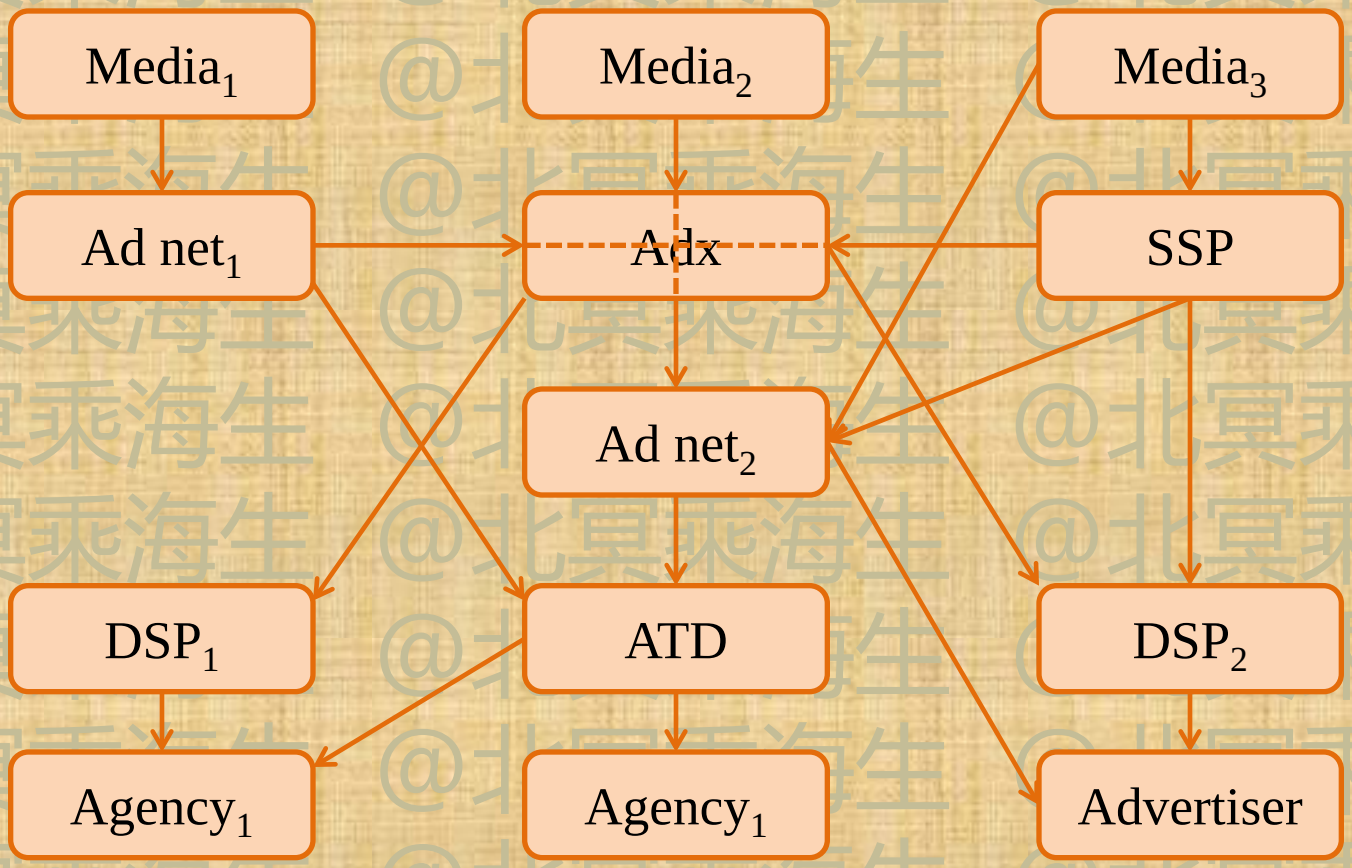

@北冥乘海生

师徒 Sheetoo

在线广告系统模块

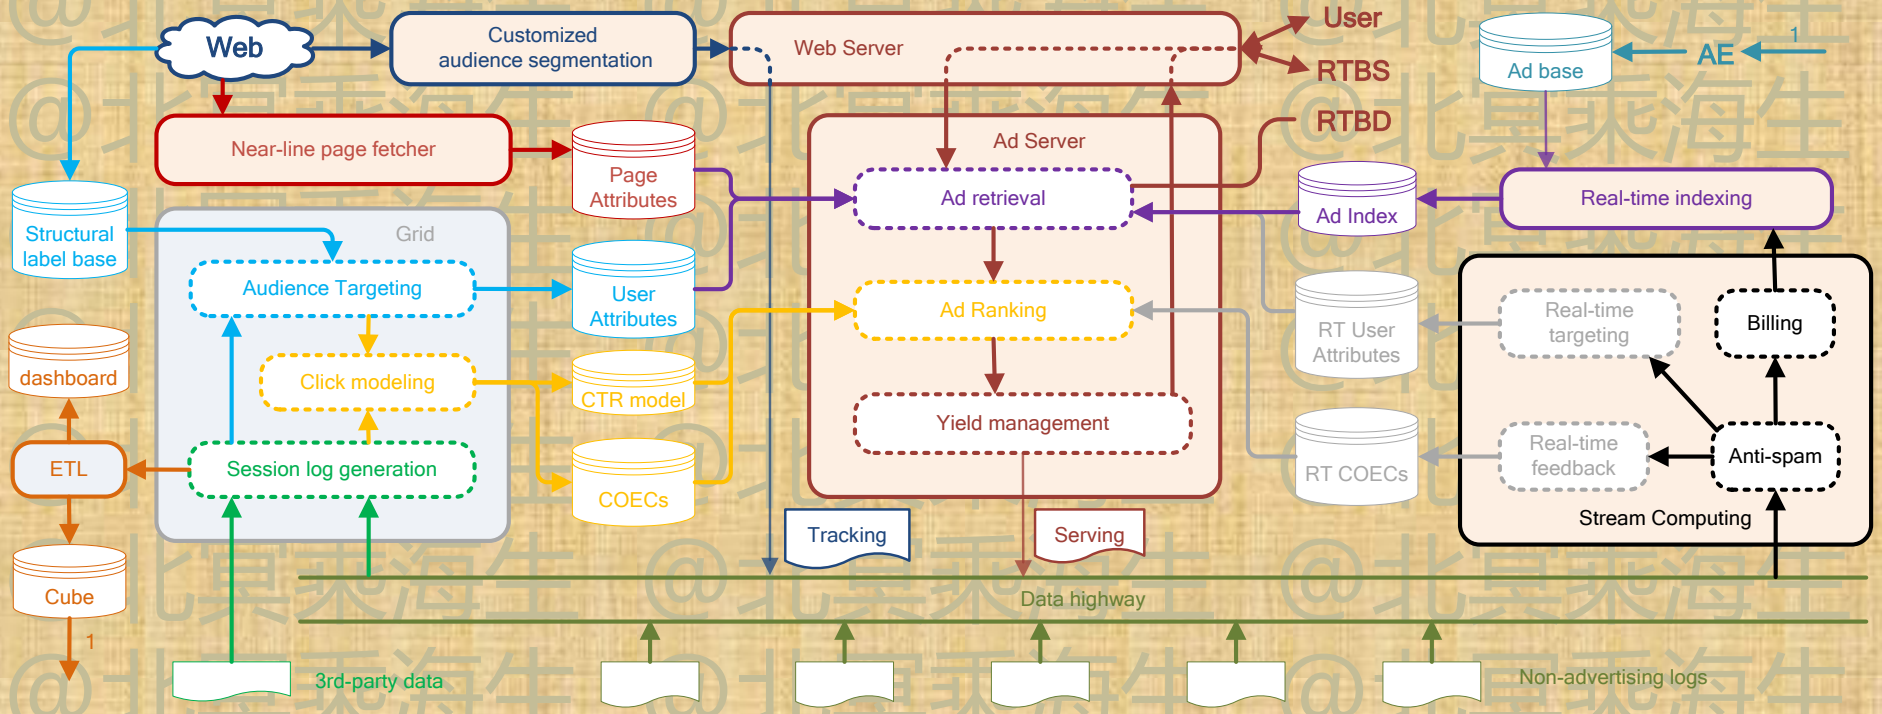

1. Ad serving
2. Ad retrieval
3. Ad ranking
4. Stream Computing
5. Data highway
6. Session log generation
7. Data warehouse
8. Customized audience segmentation
9. Page attributes system
10. Audience targeting
11. Ad management system

@北冥乘海生

广告交易市场
(Ad Exchange)

师徒 Sheetoo
@北冥乘海生

师徒 Sheetoo

广告交易平台

- 目的:
  - Platforms that facilitate the bided buying and selling of online media ad inventory from multiple ad networks
- 关键特征:
  - 用实时竞价(RTB)方式连接广告和 (上下文，用户)
  - 按照展示上的竞价收取广告主费用
- 代表:
  - Rightmedia, AdECN, GoogleAdx, OpenX

@北冥乘海生

师徒 Sheetoo

实时竞价

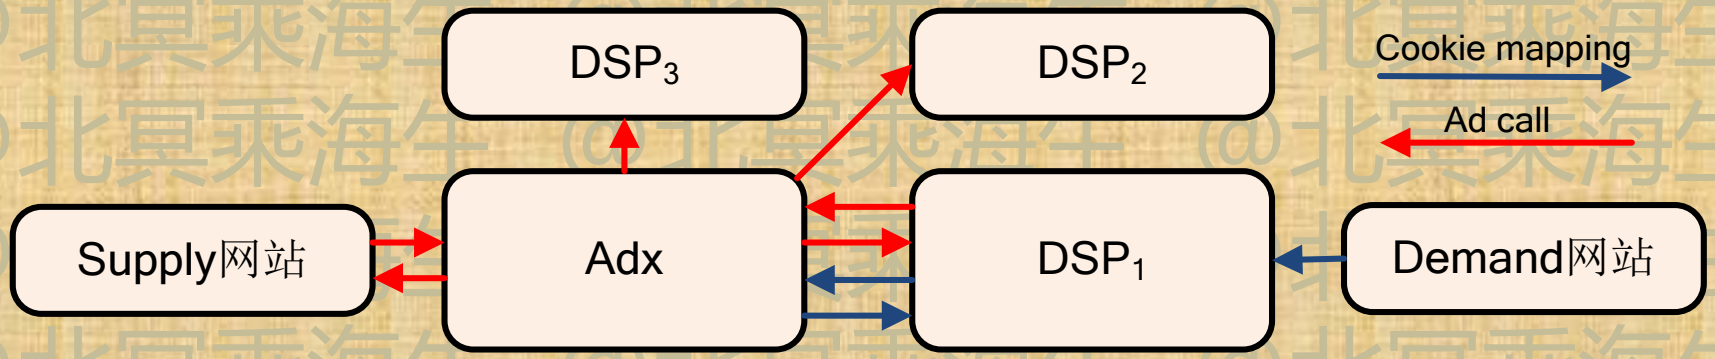

- 多方参与的过程，分为cookie mapping和ad call两阶段
- 主要技术点：
  - Adx与DSP之间的用户身份同步(cookie mapping)
  - DSP数量较多时的服务和带宽成本优化
- 潜在问题：
  - 存在浏览数据的泄露风险
  - 多一次round trip，对latency有较大影响

@北冥乘海生

师徒 Sheetoo

- 核心业务：
  - 提供媒体网络和广告主网络之间的交易平台
  - 提供托管和RTB两种交易模式
- 其他点评：
  - 在很长一短时间内并没有RTB模式
  - 目前是北美最大的广告交易平台，每天100亿次展示，有相当部分流量来自yahoo的remnant流量
  - 与Doubleclick的公开市场模式有一些不同
  - 与DMP合作以提高定向精准性和市场流动性

@北冥乘海生

Ad Exchange系统架构示意

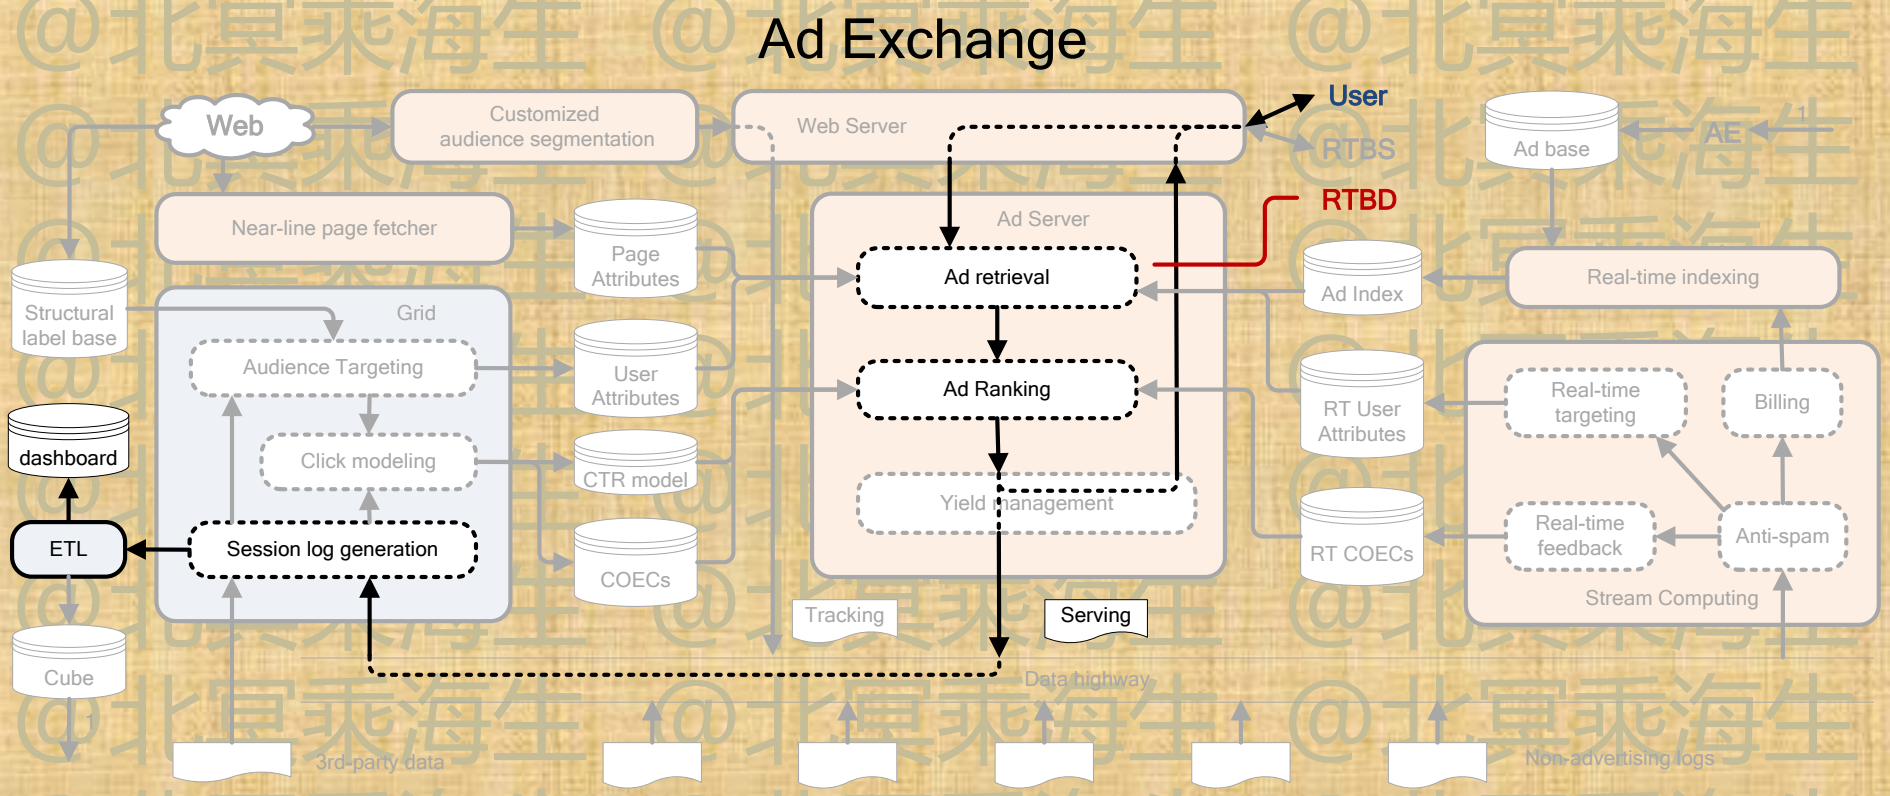

师徒 Sheetoo

Cookie Mapping

三个核心问题：谁发起？在哪里发起？谁存mapping表？

1. 选择性加载iframe, src = http://map.dsp.com/m#aid=*
2. 需要mapping的话，返回包括多个beacon的动态html
3. 发送cookie-mapping请求(xid, did, dck)
4. 302重定向(xid, xck)
5. 返回看不见的1*1 beacon

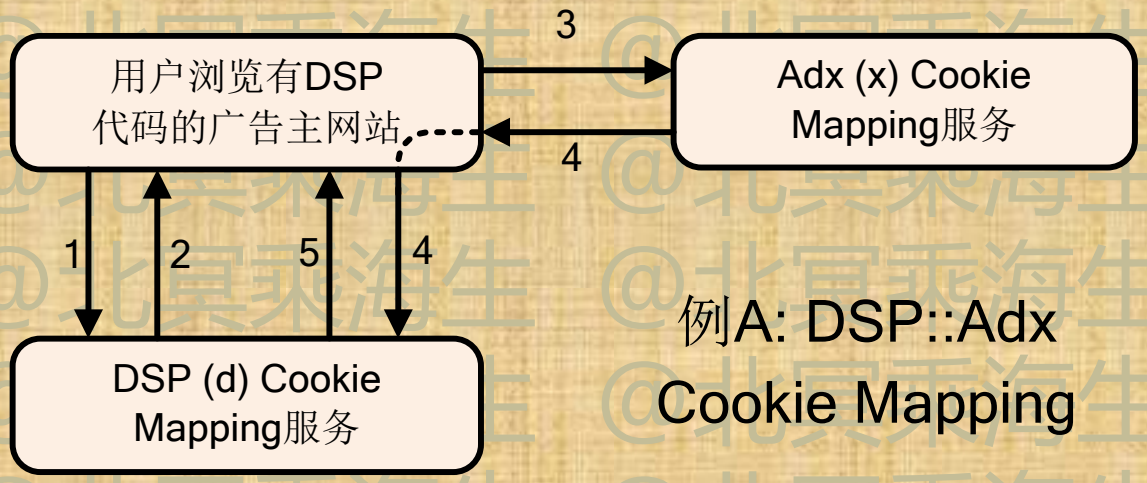

例A: DSP::Adx Cookie Mapping

1. 请求ckmapping.js
2. 返回ckmapping.js
3. 需要mapping的话，发起请求(did, mck)
4. 返回看不见的1*1 beacon

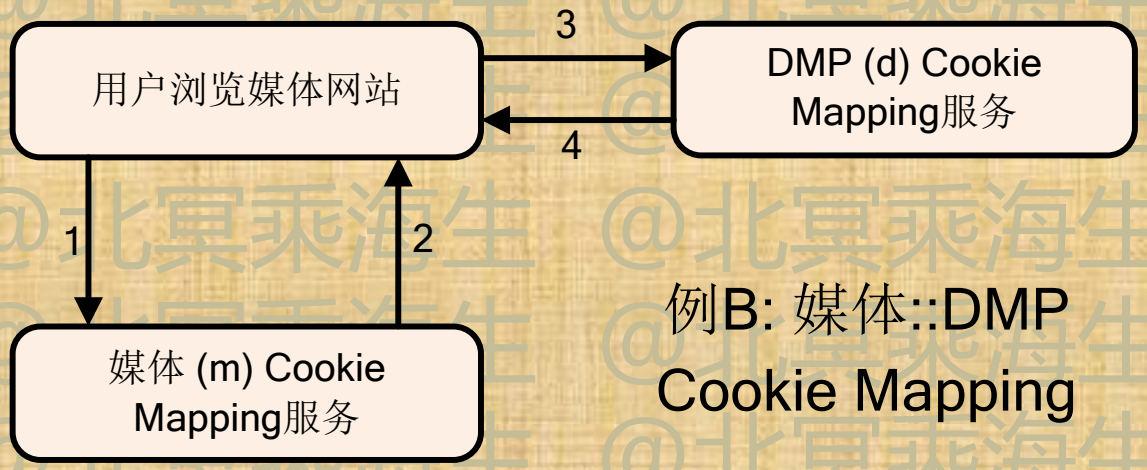

例B: 媒体::DMP Cookie Mapping