师徒 Sheetoo

Ad Network系统架构示意

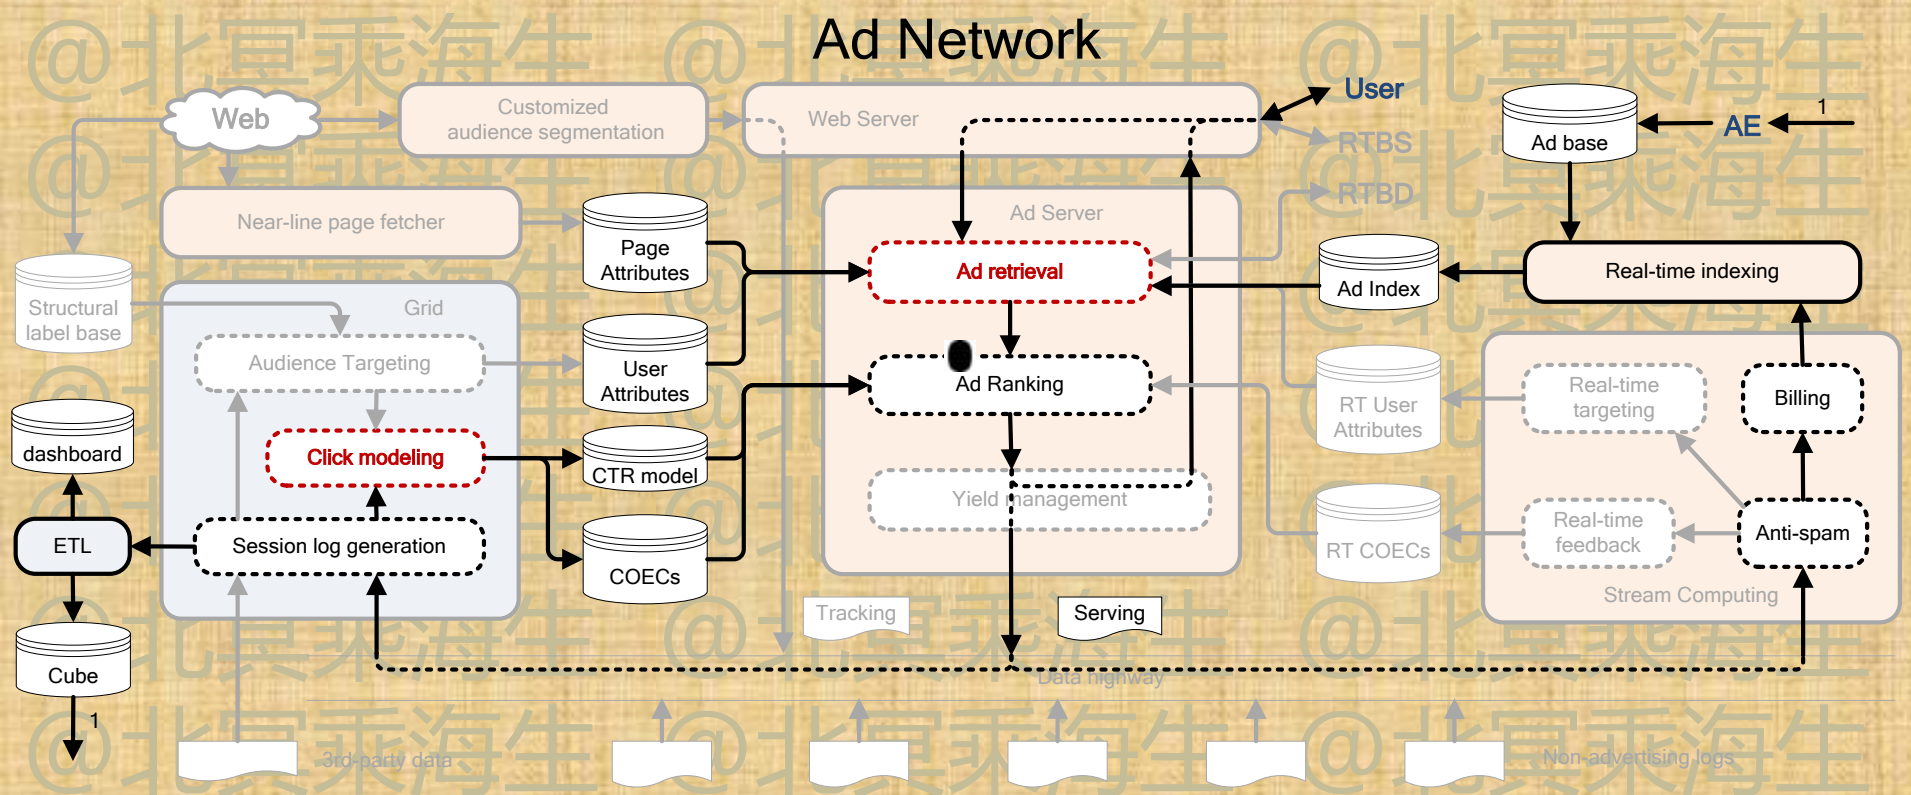

广告检索

@北冥乘海生

师徒 Sheetoo

布尔表达式检索

- 广告投放条件过滤可以视为布尔表达式检索问题
- 布尔表达式检索的一些概念
  - Doc DNF: $(age \in \{3\} \wedge state \in \{NY\}) \vee (state \in \{CA\} \wedge gender \notin \{M\})$
  - Conjunction: $age \in \{3\} \wedge state \in \{NY\}, state \in \{CA\} \wedge gender \notin \{M\}$. 同一属性在某Conjunction里只出现一次
  - Assignment: $age \in \{3\}$, $state \in \{NY\}$, $state \in \{CA\}$, …
  - sizeof[Conjunction]: conjunction包含非∉的Assignment个数
- 基本思想
  - 某查询满足conjunction，也就满足包含此conjunction的doc.
  - 维护两层倒排关系: Conjunction -> DocId，Assignment -> ConjunctionId
  - 如果sizeof(Conjunction) 大于 sizeof(query)， 则无需考虑

@北冥乘海生

师徒 Sheetoo

布尔表达式检索 – index算法

- 建立第一层 Index
  - 遍历文档DNF的Conjunction，如果为新的，则分配一个新ID(从0递增)，否则用之前分配的ConjunctionID；文档分配DocID（从0递增)；写入conjunction到doc的倒排关系，形成第一层Index
- 对于上步出现的新Conjunction，建立第二层 Index：
  - 将Conjunction切成Assignment流，Term为(属性, 值)，例: age ∈ {3;4}切成两个Term: (age, 3), (age, 4)；state ∉ {CA;NY}也切成两个Term: (state, CA), (state, NY)，∉和∈体现在倒排链表上
  - 计算Conjunction的size，将size体现在Term中，最终的Term的组成是(sizeof[Conjunction], 属性, 值)
  - 对于size为0的Conjunction，添加一个特殊的Term：Z，∈
  - 写入倒排关系, Term -> (ConjunctionID, ∈| ∉)+

@北冥乘海生

师徒 Sheetoo

布尔表达式检索 – index示例

doc1 = (age∈{3}^state∈{NY})∨(state∈{CA}^gender∈{M})=c1∨c4
doc2 = (age∈{3}^state∈{F})∨(state∉{CA;NY})=c2∨c6
doc3 = (age∈{3}^gender∈{M}^state∉{CA})∨(state∈{CA}^gender∈{F})=c3∨c7
doc4 = (age∈{3;4})∨(state∈{CA}^gender∈{M})=c5∨c4
doc5 = (state∉{CA;NY})∨(age∈{3;4})=c6∨c5
doc7 = (age∈{3}^state∈{NY})∨(state∈{CA}^gender∈{F})=c1∨c7
doc6 = (state∉{CA;NY})∨(age∈{3}^state∈{NY})∨(state∈{CA}^gender∈{M})=
c6∨c1∨c4

第一层倒排: (conjunction -> doc)

c1 -> doc-1, doc-6, doc-7
c2 -> doc-2
c3 -> doc-3
c4 -> doc-1, doc-4, doc-7
c5 -> doc-4, doc-5
c6 -> doc-2, doc-5, doc-7
c7 -> doc-3, doc-6

第二层倒排: (assignment -> conjunction)

0 (state, NY) [(c6, ∉)(c8, ∉)]
(state, CA) [(c6, ∉)]
Z [(c6, ∈)]
1 (age, 3) [(c5, ∈)]
(age, 4) [(c5, ∈)]
2 (age, 3) [(c1, ∈), (c2, ∈), (c3, ∈)]
(state, NY) [(c1, ∈)]
(gender, F) [(c2, ∈), (c7, ∈)]
(gender, M) [(c3, ∈), (c4, ∈)]
(state, CA) [(c3, ∉), (c4, ∈), (c7, ∈)]

师徒 Sheetoo

长Query情况下的相关性检索

- 根据(u,a) 广告检索时(考虑上下文定向情形)
  - Query有可能比较长, 且子Term都是Should
- 传统搜索引擎
  - 需要将所有出现过以上Term的文档都取出来，然后计算相关性并找到Top-N，在长Query和大文档集时查询速度被巨大的计算量所限制
- 一种可行的思路
  - 在查找候选DOC的过程中做一个近似的评估，切掉那些理论上不需要再考虑的文档，只对进候选的文档进行相关性计算，比Top-N最小堆最小值大的插入
  - 当相关性函数为线性时，存在有效的剪枝算法

@北冥乘海生

Weight-And (WAND) 检索算法

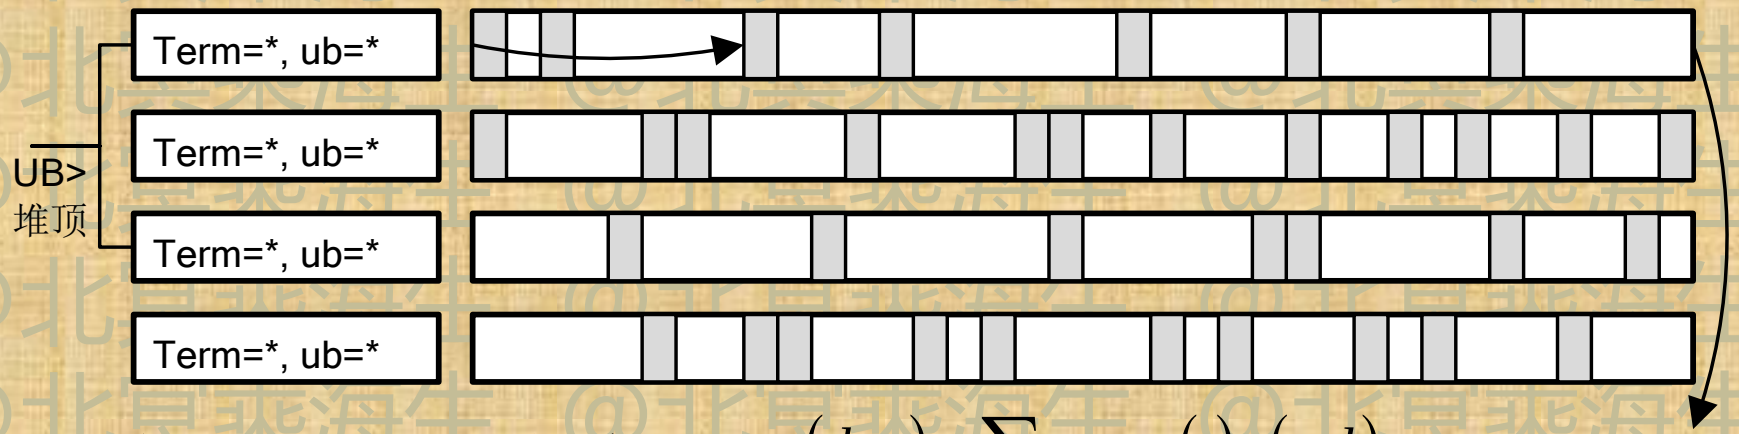

- 文档和Query相似度: $\mathrm{score}(d,q)=\sum_{t\in q\wedge d}\alpha(t)w(t,d)$
- Term贡献上界ub: $\mathrm{ub}(t)=\max_d w(t,d)$
- 文档相关性上界UB: $\mathrm{UB}(d,q)=\sum_{t\in q\wedge d}\alpha(t)\mathrm{ub}(t)\geq \mathrm{score}(d,q)$
- 检索算法概要
  - step-1: 按doclist最前面的docID对terms排序
  - step-2: 迭代terms，并累加UB直至大于堆顶，设此时到达第n-1个term，如果terms[0].doc和terms[n-1].doc一样，逼出一个doc至最小堆；如果不一样，在前n个term挑选一个skip到terms[n-1].doc，跳转至step-1.

师徒 Sheetoo
@北冥乘海生

基于WAND的上下文定向检索

- 实验为上下文内容推荐，目的是同时检测算法是否倾向于给出“Duplicate”的结果
- 编辑相关性评测 (左) & 线上测试CTR对比 (右)

相关性	Search	WAND
Exact duplicate	0.0%	0.8%
Near duplicate	7.1%	9.5%
Very related	44.4%	64.5%
Weakly related	24.0%	18.0%
Unrelated	21.1%	8.0%

内容类别	Search	WAND
Politics	0.44%	0.39%
Business	0.74%	1.02%
Entertainment	0.97%	1.32%
Crime	0.57%	1.20%
Sport	1.65%	2.27%
Health	0.47%	0.57%
Science	0.52%	0.35%
Social Issues	0.28%	0.43%
Lifestyle	0.17%	0.24%
Unrest	0.33%	0.39%
Disaster	0.10%	0.16%
Overall	**0.49%**	**0.68%**

师徒 Sheetoo
@北冥乘海生

流量预测

- 可以视为query为a, 对(u,c)进行检索的反向retrieval问题
- 由于(u,c) 联合空间规模过大，需要对u,c分别处理
- 例：上下文页面(c)索引
  - c, #impression$_c$, p_c(eCPM)

    上下文页面　该页面流量　该页面eCPM分布
  - 预测过程：
    - 给定a, 首先通过c的索引找出所有符合条件c的集合
    - 对每个c估计$e(a, c)$，并根据p_c(eCPM)得到a在c上胜出的百分比$p(a, c)$, 并将a的流量累加$p(a, c)$ x #impression$_c$

@北冥乘海生 师徒 Sheetoo

分布式同步服务 - Zookeeper

- 在基于消息传递通信模型的分布式环境下解决一致性问题的基础服务
- 用层次式Namespace维护同步需要的状态空间

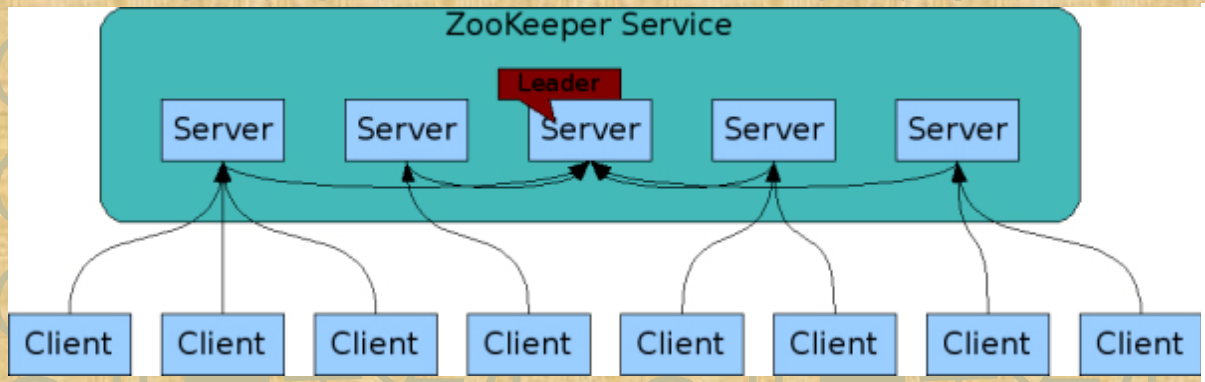

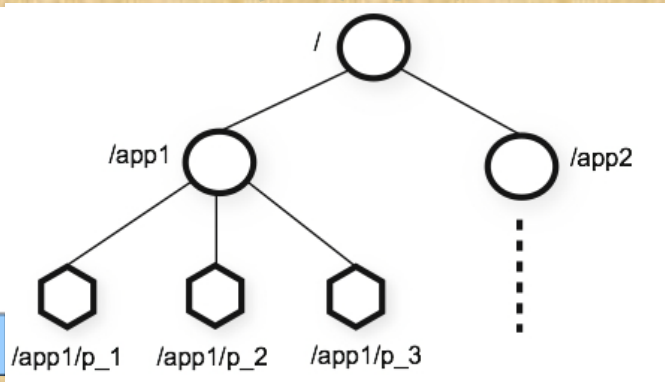

- 保证实现特性：Sequential Consistency, Atomicity, Single System Image, Reliability, Timeliness
- 较复杂的同步模式需要利用API编程实现

@北冥乘海生 师徒 Sheetoo

师徒 Sheetoo

Paxos 算法概念

- 节点角色：
  - P(roposer): (提出提案(n, value)), A(cceptor), L(earner)
- 三个约束：
  - value只有在被提出后才能被批准
  - 在一次算法的执行实例中，只批准一个value
  - learners只能获得被批准的value
- 准备阶段：
  - P选择某提案编号n并将 prepare请求发给A中的某多数派；
  - A收到消息后，若n大于它已经回复的所有消息，则将自己上次接受的提案回复给P，并承诺不再回复小于n的提案；
- 批准阶段：
  - 当P收到了多数A回复后，进入批准阶段。它要向回复请求的 A发送 accept 请求，包括编号 n 和根据约束决定的 value
  - 在不违背向其他P的承诺的前提下，A收到请求后即接受。

@北冥乘海生

点击率预测

@北冥乘海生 @北冥乘海生 @北冥乘海生
师徒 Sheetoo

师徒 Sheetoo

点击率预测

- 点击预测概率模型:

$$\mu(a,u,c) = p(\text{click} \mid a,u,c)$$

- Regression比Ranking合适一些
  - 广告的实际排序是根据eCPM，因此需要尽可能准确估计CTR，而不仅仅是各候选的CTR排序正确
- 新广告的cold-start
  - 利用广告层级结构(creative, solution, campaign, advertiser)，以及广告标签对新广告点击率做估计
- 捕获点击率的动态特性
  - 动态特征: 快速调整特征
  - 在线学习: 快速调整模型

@北冥乘海生

逻辑回归(Logistic Regression)

- Logistic Regression模型

n维特征权重矢量(参数)

$$p(\text{click} \mid a,u,c) = \sigma\left(w^{\mathrm{T}} x\right)$$

n维特征矢量

  - logistic函数 (sigmoid函数一种)

$$\sigma(t) = \frac{1}{1+e^{-t}}$$

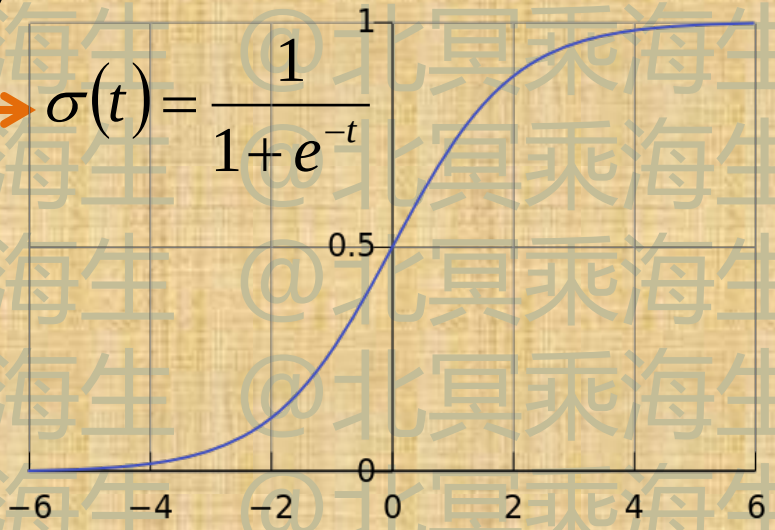

  - 视角1：Logistic regression为Generalized linear model在Binomial error情形的特例
  - 视角2：Logistic regression为Maximum entropy model在类数目等于2情形的特例

@北冥乘海生 师徒 Sheetoo

师徒 Sheetoo

逻辑回归优化方法 – L-BFGS

- BFGS (Broyden, Fletcher, Goldfarb, and Shanno)
  - Quasi-Newton方法的一种，思路为用函数值和特征的变化量来近似Hession矩阵，以保证正定性，并减少计算量
  - BFGS方法Hession计算公式 (空间复杂度为$O(n^2)$)：

$$H_{k+1} = H_k - \frac{H_k y_k y_k^{\mathrm{T}} H_k}{y_k^{\mathrm{T}} H_k y_k} + \frac{s_k s_k^{\mathrm{T}}}{y_k^{\mathrm{T}} s_k}, y_k = \nabla_{k+1} - \nabla_k, s_k = x_{k+1} - x_k$$

- L(imited memory)-BFGS
  - 将$n \times n$的Hession阵用右图方式加以近似(B_k为Hession近似)
  - 空间复杂度降为将$O(n \times k)$, 在特征量大时比BFGS实用

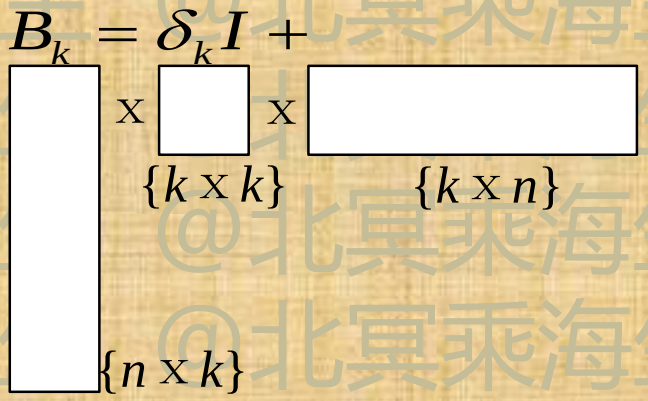

  - 可以非常容易地用map/reduce实现分布式求解：mapper求部分数据上的梯度，reducer求和并更新参数

ADMM 方法

- Alternating Direction Method of Multipliers形式

$$\min f(x)+g(z) \quad \text{s.t.} \quad Ax+Bz=c$$

- Augmented Lagrangian及迭代解法

$$L_\rho(x,z,y)=f(x)+g(z)+y^{\mathrm{T}}(Ax+Bz-c)+\frac{\rho}{2}\|Ax+Bz-c\|_2^2$$

$$x^{k+1}\leftarrow \arg\min_x L_\rho(x,z^k,y^k);\ z^{k+1}\leftarrow \arg\min_z L_\rho(x^{k+1},z,y^k)$$

$$y^{k+1}\leftarrow y^k+\rho(Ax^{k+1}+Bz^{k+1}-c)$$

- Scaled Form: $(u=(1/\rho)y)$

$$x^{k+1}\leftarrow \arg\min_x\left(f(x)+(\rho/2)\|Ax+Bz^k-c+u^k\|_2^2\right)$$

$$z^{k+1}\leftarrow \arg\min_z\left(g(z)+(\rho/2)\|Ax^{k+1}+Bz-c+u^k\|_2^2\right)$$

$$u^{k+1}\leftarrow u^k+Ax^{k+1}+Bz^{k+1}-c$$

@北冥乘海生 师徒 Sheetoo

逻辑回归的ADMM分布式解法

- 样本划分的逻辑回归ADMM问题

$$\min \sum_{i=1}^{N} \sigma(A_i x_i) + r(z)$$

$$\text{s.t.} \quad x_i - z = 0, \qquad i = 1, \cdots, N$$

- 分布式迭代解

$$x_i^{k+1} \leftarrow \arg\min_{x_i} \left(\sigma(A_i x_i) + \frac{\rho}{2} \left\| x_i - z^k + u_i^k \right\|_2^2 \right)$$

$$z^{k+1} \leftarrow \arg\min_{z} \left(r(z) + \frac{N\rho}{2} \left\| z - \bar{x}^{k+1} + \bar{u}^k \right\|_2^2 \right)$$

$$u_i^{k+1} \leftarrow u_i^k + x_i^{k+1} - z^{k+1}$$

@北冥乘海生 师徒 Sheetoo

动态特征 - 多层次点击反馈

- 在标签组合维度上聚合点击反馈统计作为CTR预测的特征
- 优势:
  - 工程架构扩展性强(与在线学习相比)
  - 对新(a, u, c)组合有较强back-off能力
- 缺点:
  - 在线特征的存储量大，更新要求高
- 组合维度举例:
  - cookie(u) and creative(a)
  - gender(u) and topic(c)
  - location(u) and advertiser(a)
  - Category(a) and category(u)
  - cookie(u)
  - creative(a)
  - gender(u)

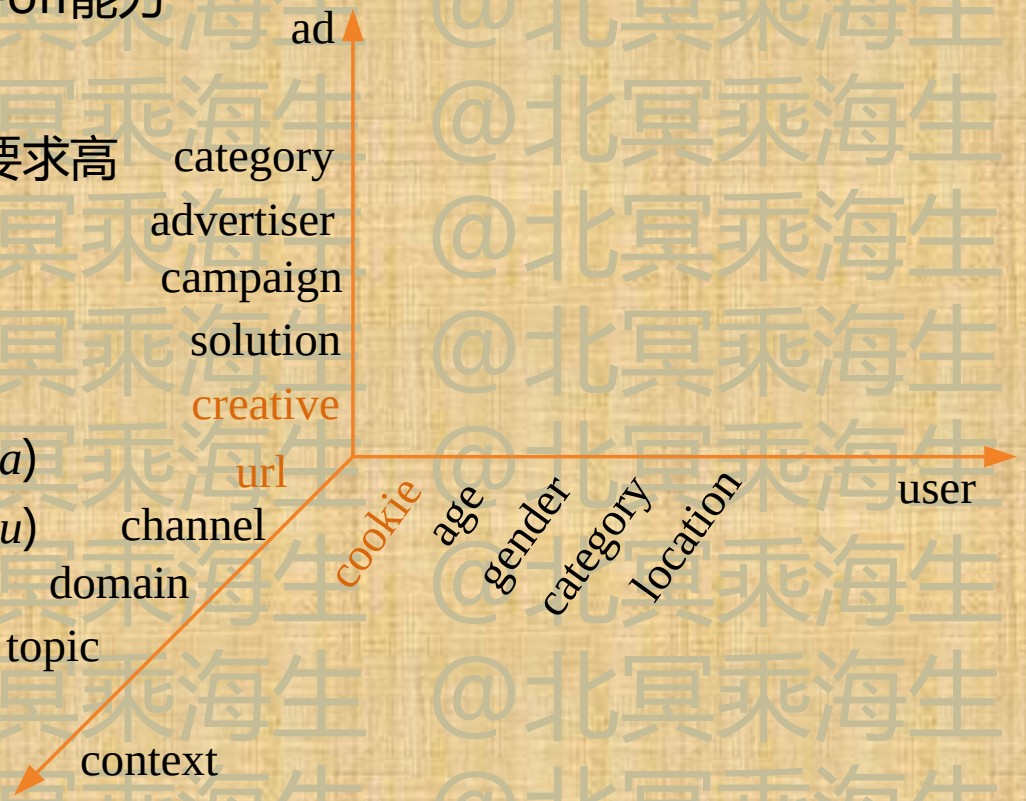

@北冥乘海生